ТЕОРЕТИЧЕСКИЕ ОСНОВЫ ОТСЛЕЖИВАНИЯ ПАРТИТУРЫ В РЕАЛЬНОМ ВРЕМЕНИ: ОТ СКРЫТЫХ МАРКОВСКИХ МОДЕЛЕЙ И ON-LINE TIME WARPING К ОБУЧЕНИЮ С ПОДКРЕПЛЕНИЕМ

Н. А. Новицкий[1,*] , Н. С. Борисов[2,†]

[1] *АНО Центральный Университет, бывш. НИУ ВШЭ*
[2] *АНО Центральный Университет*

Аннотация. Отслеживание партитуры в реальном времени — задача синхронизации живого исполнения с её символьной записью, лежащая в основе автоматического аккомпанемента, обучающих систем и виртуальных оркестров. В настоящей работе проводится систематическое теоретическое изложение моделей и алгоритмов, развитых в области с 1978 по 2026 год: от классического динамического программирования Сакоэ-Чибы [1] и каузальной модификации Диксона для On-line Time Warping [2], через скрытые марковские модели [3, 4], гибридные модели с явной длительностью состояний [5, 6], до современных нейросетевых подходов [7, 8]. Отдельно подробно разбирается недавнее семейство методов на основе обучения с подкреплением, начиная с работы Дорфера и коллег [9] и до работ Петер [10] и Ву [11], и формулируется теоретическая постановка нового гибридного подхода, в котором RL-агент действует как тонкий слой опережающего предсказания темпа поверх вероятностного трекера, а не заменяет его целиком. Кроме того, обсуждаются перспективы переноса методов слотированного символьного марковского моделирования и distribution fields из астроинформатики в задачу отслеживания партитуры. Работа имеет теоретический характер: численные эксперименты не приводятся и обозначены как направления продолжения исследования.

Ключевые слова: отслеживание партитуры, скрытые марковские модели, скрытая полумарковская модель, on-line time warping, обучение с подкреплением, опережающее предсказание темпа, PPO, GAE, distribution fields, multiview metric learning, виртуальный оркестр, аккомпанемент в реальном времени

ВВЕДЕНИЕ

Автоматический аккомпанемент относится к числу старейших и наиболее требовательных задач анализа музыкальной информации. Солист ожидает, что оркестр будет следовать за его темпом, динамикой и артикуляцией в реальном времени; для убедительной иллюзии живого ансамбля суммарная задержка между моментом звукоизвлечения солиста и соответствующим оркестровым событием не должна превышать 20 мс — порог восприятия рассинхронизации в музыкальном ансамбле [5, 12]. Технически эта задача формулируется как *отслеживание партитуры в реальном времени* (*score following*) [13]: по поступающему каузально потоку наблюдений (MIDI-событий или аудиосигнала) и заранее известной символьной партитуре требуется оценивать текущую позицию исполнителя и при необходимости управлять воспроизведением сопровождения.

Развитие области охватывает более четырёх десятилетий и прошло через несколько принципиальных этапов. Первоначально — работы Данненберга [13] и Веркоу [12], независимо опубликованные в 1984 году, — задача решалась средствами динамического программирования, перенесёнными из области распознавания речи [1]. На рубеже двухтысячных доминирующей рамкой стало вероятностное моделирование с использованием скрытых марковских моделей [3], позволившее естественно описывать неопределённость в текущей позиции и ошибки исполнителя [4–6, 14]. С 2018 года интенсивно развиваются нейросетевые и глубокие подходы, обучаемые непосредственно на больших корпусах выровненных аудиозаписей [7, 8, 15]. Параллельно появилось отдельное направление, формализующее отслеживание партитуры как задачу обучения с подкреплением [9–11, 16], и обзорная работа [17] систематизирует возникшее многообразие живых музыкальных агентов.

Настоящая работа имеет *теоретический и обзорный характер*. Её цели сводятся к четырём пунктам: во-первых, дать единое математическое изложение основных моделей и алгоритмов отслеживания партитуры — от Dynamic Time Warping и On-line Time Warping до полу-марковских моделей с явной длительностью [5] и HMM-моделей с обработкой ошибок [6]; во-вторых, систематически рассмотреть фундаментальные методы обучения с подкреплением, релевантные для нашей задачи (PPO, GAE, обучение по предпочтениям [18–20]), и провести подробный обзор всех известных авторам работ, применяющих обучение с подкреплением непосредственно к задаче музыкального аккомпанемента или отслеживания партитуры [9–11, 16, 21]; в-третьих, сформулировать теоретическую постановку нового гибридного подхода, в котором RL-агент действует как *тонкий слой опережающего предсказания темпа* поверх классического вероятностного трекера, а не заменяет его целиком, и обсудить, чем такая постановка отличается от

* n.novitskiy@edu.centraluniversity.ru
† n.borisov@edu.centraluniversity.ru

существующих RL-подходов; в-четвёртых, обсудить перспективы переноса в задачу отслеживания партитуры методов *slotted symbolic Markov modeling* и *distribution fields*, оригинально развитых в астроинформатике для классификации временных рядов переменных звёзд [22–24].

Работа сознательно не содержит численных экспериментов: цель статьи — дать математически выверенный, полный и прослеживаемый по литературе теоретический фундамент, на который можно опираться при последующем практическом внедрении. Все обсуждаемые количественные характеристики (точность выравнивания, задержка, F1-мера onset-событий) приводятся с прямой ссылкой на источник и описывают результаты оригинальных авторов, а не настоящей работы.

Структура изложения соответствует перечисленным целям. В разд. II проводится обзор существующих работ, разбитый на четыре тематических блока: классические DP-следователи, HMM-модели, современные нейросетевые подходы и обучение с подкреплением для музыки. В разд. III формализуется задача отслеживания партитуры. В разд. IV последовательно излагается математический аппарат: DTW и его on-line модификация, базовая HMM Рабинера [3], полу-марковские модели и гибридная архитектура Конта [5], а также два метода-кандидата на перенос из астроинформатики — SSMM и distribution fields. В разд. VI приводится фундамент обучения с подкреплением в объёме, необходимом для понимания современных методов: марковские процессы принятия решений, оценка преимуществ, алгоритм PPO, обучение по предпочтениям. В разд. VII детально разбираются известные нам работы, применяющие RL к музыкальному аккомпанементу или отслеживанию партитуры; для каждой указывается постановка MDP, архитектура агента, функция вознаграждения и характер новизны. В разд. VIII формулируется теоретическая постановка нашей гибридной схемы. В разд. IX обсуждаются открытые вопросы и ограничения, в разд. X — итоги и направления дальнейшей работы. Полные псевдокоды Forward, Viterbi, Forward для гибридной полу-марковской модели и схема обучения PPO вынесены в Приложения А–Г.

ОБЗОР СУЩЕСТВУЮЩИХ РАБОТ

Существующие работы по отслеживанию партитуры удобно сгруппировать в четыре тематических направления, отражающих историческую последовательность развития области и одновременно различающихся по типу применяемого математического аппарата. Ниже последовательно рассматриваются: классические алгоритмы динамического программирования и их каузальные модификации; вероятностные модели на основе скрытых марковских процессов и их полу-марковских расширений; современные нейросетевые подходы; и относительно недавно сформировавшееся семейство методов, в которых отслеживание партитуры формулируется как задача обучения с подкреплением.

Классические алгоритмы динамического программирования. Современные методы выравнивания временных рядов берут начало с работы Сакоэ и Чибы [1], в которой для задачи распознавания речи введён алгоритм Dynamic Time Warping и его теперь стандартная полоса ограничений. Перенос идей в задачу отслеживания партитуры независимо предложен Данненбергом и Веркоу [12, 13]: оба автора рассматривают исполнение и партитуру как два потока однотипных событий и сопоставляют их по принципу динамического программирования с допуском ошибок. Существенным каузальным расширением является On-line Time Warping Диксона [2], в котором матрица накопленных стоимостей заполняется столбец за столбцом по мере поступления новых наблюдений, а специальный счётчик $RunCount$ ограничивает число последовательных шагов в одном направлении и тем самым предотвращает «застревание» алгоритма. Подробное изложение DTW и музыкальных применений приведено в монографии Мюллера [25] и более поздней учебной книге [26], а в диссертации Арцта [27] систематизирован опыт построения надёжных DP-следователей под концертные условия.

Вероятностные модели на основе скрытых марковских процессов. Учебная статья Рабинера [3] остаётся канонической ссылкой для алгоритмов Forward, Backward, Viterbi и переоценки параметров методом Баума-Уэлча; именно эта нотация используется во всём дальнейшем изложении. Применение HMM к задаче отслеживания партитуры впервые систематически проведено в работе Орио и Дешелля [4]: предложена двухуровневая модель, в которой нижний уровень моделирует ноты как фазы attack–sustain–silence, а верхний — допустимые ошибки исполнителя через параллельные «теневые» состояния. Конт с соавторами [28] развил эту линию до иерархической HMM с разреженными неотрицательными ограничениями для полифонического выравнивания. Ключевым теоретическим достижением оказалась работа Конта [5], в которой предложена *гибридная* архитектура из двух связанных вероятностных агентов — аудио-агента и темпо-агента — работающих в одной байесовской инференц-схеме; при этом темпоральные элементы партитуры моделируются как полу-марковский процесс с явным распределением длительностей $d_j(u)$, а атемпоральные (орнаменты, трели) — как обычный марковский процесс с геометрической длительностью. Эта архитектура положена в основу системы Antescofo, активно используемой в концертной практике IRCAM с 2007 года. Параллельно Рафаэль [14] развивал родственный, но самостоятельный подход — переключающиеся пространства состояний с явным гауссовским тайминг-моделем для пары (t_n, s_n), объединённой с HMM-наблюдательной частью; в системе Music Plus One этот подход позволяет адаптироваться к конкрет-

ному солисту от репетиции к репетиции через off-line EM. Накамура с соавторами [6] рассмотрели задачу в наиболее общей постановке — с произвольными повторами, пропусками и фальшивыми нотами — и предложили факторизацию переходного графа, понижающую сложность шага Forward с $O(N^2)$ до $O(N)$.

Современные нейросетевые подходы. С 2018 года активно развивается семейство методов, обучаемых сквозным образом на больших корпусах выровненных аудиозаписей. Хоторн с соавторами [7] в работе Onsets and Frames ввели двойную целевую функцию — покадровое присутствие ноты плюс отдельную голову для onset-событий; их же работа 2019 года [15] ввела датасет MAESTRO объёмом 172.3 ч с точностью выравнивания около 3 мс, который стал стандартным бенчмарком для пианистической транскрипции. Арцт и Латтнер [29] предложили обучаемые транспозиционно-инвариантные признаки на основе gated-autoencoder'a, превратив задачу audio-to-score в задачу audio-to-audio выравнивания после синтеза партитуры через семплер. Хенкель и Видмер [8] разработали систему Conditional YOLO с условием FiLM-параметров от аудио, ведущую следование непосредственно по *изображению* партитуры на трёх разрешениях (нота, такт, система); такая постановка снимает зависимость от дорогой нотно-уровневой разметки. Аграваль и Диксон [30] рассмотрели гибридную схему, в которой обученный сиамской CNN признак заменяет ручную chroma в матрице сходства, а само выравнивание по-прежнему ведётся методом DTW.

Обучение с подкреплением для отслеживания партитуры и аккомпанемента. Принципиально иная постановка предложена Дорфером и коллегами [9]: задача формулируется как мультимодальный марковский процесс принятия решений, в котором состояние объединяет окно изображения партитуры с участком спектрограммы, а действие изменяет скорость продвижения курсора по партитуре с шагом Δv_{px1}. Обучение ведётся методом advantage actor–critic с шестнадцатью параллельными акторами и плотной линейной функцией вознаграждения $r = 1 - |d_x|/b$ внутри окна допустимых отклонений. Петер [10] предложил вариант для символьного выравнивания с офлайновым обучением через offline RL: трансформер аппроксимирует Q-функцию, но с дисконтом $\gamma = 0$ (полностью близорукий агент), благодаря чему задача сводится к бинарной классификации правильности выбранного onset-кандидата. Его система достигает медианной асинхронности 15.7 мс (против 60.6 мс у OLTW), что является лучшей известной авторам цифрой для онлайн-выравнивания символьного входа. Цзян с соавторами [16] в системе RL-Duet применили актор-критик с обобщённой оценкой преимуществ [19] к задаче генерации гармонического сопровождения для монофонической мелодии; функция вознаграждения собирается из ансамбля четырёх специализированных нейросетевых критиков. Ву с соавторами [11] в работе ReaLchords развили эту линию через KL-контроль к офлайновому учителю, видящему всю мелодию целиком; такой подход формально решает проблему *exposure bias* при онлайн-генерации. Жак с соавторами [21] ранее предложили KL-контроль как общий приём дообучения предобученной MLE-модели последовательности с эвристическим внешним вознаграждением. Обзорная работа Кима с соавторами [17] систематизирует 184 систему живых музыкальных агентов в четырёх измерениях (Usage Context, Interaction, Technology, Ecosystem) с 31 детальной осью.

Перенос методов из астроинформатики. Отдельным направлением, ранее не представленным в литературе по MIR, являются методы slotted symbolic Markov modeling (SSMM) [23] и distribution fields [24], изначально развитые для классификации переменных звёзд по нерегулярным фотометрическим рядам [22]. Перенос этих методов в задачу отслеживания партитуры обсуждается в разд. V.

Положение настоящей работы. В отличие от работ [9, 10], в которых RL-агент *заменяет* классический трекер целиком, и работ [11, 16], в которых RL применяется к генерации музыки, а не к её отслеживанию, в разд. VIII обсуждается теоретическая возможность построения гибридной схемы: классический вероятностный трекер сохраняется как ядро, а RL-агент действует как *тонкий слой опережающего предсказания темпа* с целью компенсации задержек воспроизводящей части системы. Такая постановка не противоречит результатам указанных работ и формально дополняет их.

ФОРМАЛЬНАЯ ПОСТАНОВКА ЗАДАЧИ

Партитура задаётся последовательностью $S = \{(p_i, t_i^{\mathrm{on}}, t_i^{\mathrm{off}})\}_{i=1}^{N}$ из N нот, в которой $p_i \in \{0, \ldots, 127\}$ — высота в стандарте MIDI, а $t_i^{\mathrm{on}}, t_i^{\mathrm{off}}$ — номинальные моменты начала и конца звучания относительно некоторого базового темпа v_0 (как правило, в beat-единицах). Исполнение поступает каузально как поток $P = \{(q_j, \tau_j^{\mathrm{on}}, \tau_j^{\mathrm{off}})\}_{j=1}^{M}$ с реализованными высотами q_j и реальными моментами времени τ_j, причём M заранее не известно.

Задача отслеживания партитуры состоит в построении *каузального* отображения

$$\varphi : \{1, \ldots, M\} \longrightarrow \{1, \ldots, N\}, \qquad j \mapsto \varphi(j), \tag{1}$$

ставящего в соответствие каждому событию исполнения с номером j позицию $\varphi(j)$ в партитуре, причём оценка $\hat{\varphi}(j)$ вычисляется по информации только из прошлого: $q_1, \tau_1, \ldots, q_j, \tau_j$. Поскольку в большинстве музыкальных контекстов исполнитель движется по партитуре вперёд (с возможными редкими пропусками, повторами и ошибками [6], но без систематического возврата назад), отображение φ обычно требуют удовлетворяющим условию монотонности

$$j_1 < j_2 \Longrightarrow \varphi(j_1) \le \varphi(j_2). \tag{2}$$

Для практического применения отображение φ дополняется оценкой текущего темпа исполнения $\hat{v}(t) >$

0, выражающей скорость движения исполнителя по партитуре в beat/секунду. Темп используется блоком воспроизведения сопровождения для синхронного синтеза оркестровой партии. В наиболее общей постановке [5, 14] обе величины оцениваются совместно, а не последовательно: апостериорное распределение по позиции зависит от текущей оценки темпа, а оценка темпа — от истории согласованных событий.

Задача характеризуется тремя дополнительными требованиями. *Каузальность:* оценка $\hat{\varphi}(j)$ должна быть доступна не позже момента $\tau_j + L$, где L — допустимая задержка системы. *Робастность:* ошибки исполнителя (пропуски нот, фальшивые ноты, орнаменты), не предусмотренные партитурой, не должны приводить к потере синхронизации. *Адаптивность:* оценка темпа должна реагировать на выразительные изменения исполнителя — ритардандо, ачелерандо, rubato — не теряя устойчивости.

В дальнейшем используется единая нотация: $\lambda = (A, B, \pi)$ для параметров скрытой марковской модели с матрицей переходов $A = (A_{ij})$, эмиссионными распределениями $b_i(o)$ и начальным распределением π_i [3]; $\alpha_t(j)$, $\beta_t(j)$ для прямой и обратной переменных алгоритма Forward/Backward; $\delta_t(j)$, $\psi_t(j)$ для алгоритма Viterbi; $d_j(u)$ для распределения длительности пребывания в состоянии j полу-марковской модели [5]; $\mathscr{M} = (\mathscr{S}, \mathscr{A}, \mathscr{T}, r, \gamma)$ для марковского процесса принятия решений [31], в котором $\mathscr{S}$ — пространство состояний, $\mathscr{A}$ — действий, $\mathscr{T}$ — ядро переходов, r — функция вознаграждения, $\gamma \in [0,1]$ — дисконт-фактор.

МАТЕМАТИЧЕСКИЕ ОСНОВЫ МОДЕЛЕЙ ОТСЛЕЖИВАНИЯ ПАРТИТУРЫ

Математический аппарат отслеживания партитуры удобно строить от простого к сложному: первый кирпич — классический алгоритм Dynamic Time Warping, второй — его каузальная модификация On-line Time Warping, третий — скрытые марковские модели в формулировке Рабинера [3] и их прикладная адаптация для отслеживания партитуры, четвёртый — полумарковские расширения с явной длительностью состояний и гибридная архитектура Конта [5]. Все обозначения соответствуют принятой в литературе нотации [3, 5, 25], и для самостоятельности изложения каждая модель выводится из предшествующей. Отдельно (см. разд. V) обсуждаются два метода — slotted symbolic Markov modeling и distribution fields, — оригинально развитые в смежной области астроинформатики и потенциально применимые в нашей задаче.

Запись партитуры на нотном стане. Прежде чем формализовать математику, полезно зафиксировать сам объект изучения. Партитура — это упорядоченная последовательность нот; каждой ноте соответствует пара (высота, длительность). В дальнейшем для сквозного учебного примера используем мажорное арпеджио из пяти нот: $S_{\text{ex}} = (\text{C4, E4, G4, A4, C5})$, с MIDI-кодами $(60, 64, 67, 69, 72)$ соответственно. Этот пример выбран минимальным: пять нот достаточно, чтобы проиллюстрировать все рекуррентные формулы, и одновременно короток для пошагового численного разбора.

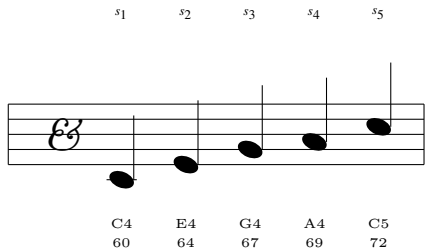

РИС. 1. Сквозной учебный пример: пять нот (C4, E4, G4, A4, C5) на нотном стане в скрипичном ключе. На все последующие алгоритмы DTW, HMM и Forward будут применяться именно к этому фрагменту.

Dynamic Time Warping. Алгоритм DTW строит оптимальное выравнивание двух последовательностей $A = (a_1, \ldots, a_I)$ и $B = (b_1, \ldots, b_J)$ через минимизацию суммарной локальной стоимости вдоль некоторого пути $F = c(1), c(2), \ldots, c(K)$, где $c(k) = (i(k), j(k))$. По Сакоэ и Чибе [1] локальная стоимость определяется как $d(i,j) = \|a_i - b_j\|$, взвешенная сумма по пути — как $E(F) = \sum_k d(c(k))\, w(k)$, а нормализованное расстояние — через минимизацию

$$D(A,B) = \min_F \frac{\sum_{k=1}^{K} d(c(k))\, w(k)}{\sum_{k=1}^{K} w(k)}, \tag{3}$$

где допустимые пути удовлетворяют условиям монотонности $i(k-1) \le i(k)$, $j(k-1) \le j(k)$, граничным $c(1) = (1,1)$, $c(K) = (I,J)$ и шага не более единицы по каждой координате. Для практической реализации применяется рекурсивная DP-формулировка [1, уравн. 16–18]: $g_1(c(1)) = d(c(1))\, w(1)$,

$$g_k(c(k)) = \min_{c(k-1)} \left[g_{k-1}(c(k-1)) + d(c(k))\, w(k) \right], \tag{4}$$

$D(A,B) = g_K(c(K))/N$, где $N = \sum_k w(k)$. Для симметричных весов $w(k) = (i(k) - i(k-1)) + (j(k) - j(k-1))$ и нулевого ограничения наклона рекурсия принимает компактный вид

$$g(i,j) = \min \begin{cases} g(i-1, j-1) + 2d(i,j), \\ g(i-1, j) + d(i,j), \\ g(i, j-1) + d(i,j), \end{cases} \tag{5}$$

с инициализацией $g(1,1) = 2d(1,1)$ и итоговым $D(A,B) = g(I,J)/(I+J)$. Для уменьшения вычислительной сложности с $O(NM)$ до $O(NR)$ применяется *полоса Сакоэ-Чибы* $|i(k) - j(k)| \le R$ [1, уравн. 8].

В контексте отслеживания партитуры [25, 27] последовательность A обычно соответствует синтезированной по партитуре аудиодорожке (или последовательности нот), B — живому исполнению; локальная стоимость $d(i,j)$ строится по chroma-векторам, спектральным признакам или, как в современной работе [29], по обучаемым транспозиционно- инвариантным эмбеддингам.

Пример заполнения матрицы DTW. Пусть партитура — наш сквозной пример $S_{\text{ex}} = (60, 64, 67, 69, 72)$, а исполнение содержит шесть событий с реализованными высотами $P_{\text{ex}} = (60, 64, 67, 67, 69, 72)$ (третья нота сыграна дважды — типичная исполнительская «зацепка»). В качестве локальной стоимости используем $d(i,j) = |\text{midi}(s_i) - q_j|$ в полутонах. Прямой расчёт матрицы $g(i,j)$ по уравн. (5) даёт нижеследующую таблицу (показаны только значения внутри полосы Сакоэ-Чибы $|i-j| \le 2$, остальные ячейки помечены прочерком):

$i \backslash j$	1	2	3	4	5	6
1 (C4=60)	**0**	4	—	—	—	—
2 (E4=64)	4	**0**	3	3	—	—
3 (G4=67)	—	3	**0**	**0**	2	—
4 (A4=69)	—	—	2	2	**0**	3
5 (C5=72)	—	—	—	5	3	**0**

Жирным показан оптимальный путь $W = (1,1) \to (2,2) \to (3,3) \to (3,4) \to (4,5) \to (5,6)$, соответствующий выравниванию: первая нота партитуры $\to$ первая исполнения, вторая $\to$ вторая, третья нота партитуры покрывает *два* последовательных наблюдения исполнения (это и есть «зацепка»), затем выравнивание продолжается стандартно. Итоговая нормированная стоимость пути — 0, поскольку все совпадения точные.

Геометрически путь визуализируется как ломаная в матрице накопленных стоимостей; пример более общей картины приведён на РИС. 2.

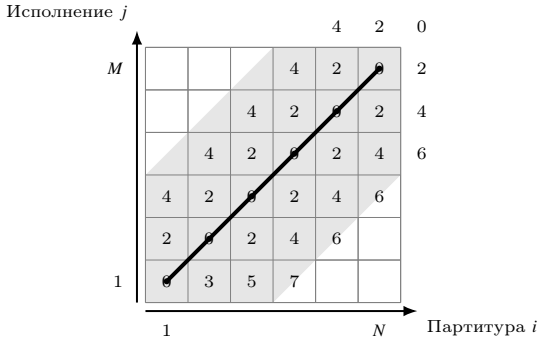

РИС. 2. Матрица накопленных стоимостей DTW для пятинотного фрагмента (схематическая иллюстрация). Серым выделена полоса Сакоэ-Чибы при $R = 2$, чёрной ломаной — оптимальный путь выравнивания.

On-line Time Warping. Каузальная модификация DTW предложена Диксоном [2] для случая, когда последовательность B поступает потоково и заранее не известна. Алгоритм поддерживает две позиции — текущую строку i_{cur} и текущий столбец j_{cur} — и при поступлении новой ноты q_j обновляет столбец матрицы D в окне $[i_{\text{cur}} - W, i_{\text{cur}} + W]$ согласно стандартной DP-рекурсии уравн. (5). Выбор следующей ячейки определяется минимизацией нормализованной частичной стоимости среди трёх возможных направлений (увеличить строку, столбец или оба индекса одновременно). Особенностью алгоритма является счётчик *RunCount*: если выбор направления повторяется более $R_{\max}$ раз подряд, обработка принудительно переключается на ортогональное направление, что предотвращает застревание на одной строке партитуры в случае акустически неоднозначных моментов. Параметр $R_{\max}$ типично выбирается равным 3 [2]; ширина окна W задаётся как $\lceil \alpha N \rceil$ с $\alpha \approx 0.1$.

Скрытая марковская модель. Скрытая марковская модель [3] с конечным числом состояний $\mathscr{S} = \{S_1, \ldots, S_N\}$ и наблюдениями $O = (o_1, \ldots, o_T)$ полностью характеризуется тройкой $\lambda = (A, B, \pi)$, где $A = (A_{ij})$ — матрица переходов $A_{ij} = \mathbb{P}(q_{t+1} = S_j \mid q_t = S_i)$, B — эмиссионные распределения $b_i(o) = \mathbb{P}(o \mid q_t = S_i)$, $\pi = (\pi_i)$ — начальное распределение $\pi_i = \mathbb{P}(q_1 = S_i)$. Стохастические ограничения требуют $\sum_j A_{ij} = 1$, $\sum_o b_i(o) = 1$ и $\sum_i \pi_i = 1$.

В формулировке Рабинера [3, стр. 261] перед исследователем стоят три фундаментальные задачи: *задача оценивания* — вычислить $\mathbb{P}(O \mid \lambda)$ для заданной последовательности наблюдений и параметров; *задача декодирования* — найти наиболее вероятную последовательность скрытых состояний $\hat{Q}^* = \arg\max_Q \mathbb{P}(Q \mid O, \lambda)$; *задача обучения* — подобрать параметры λ, максимизирующие правдоподобие наблюдений.

Ключевым инструментом для решения первых двух задач является *прямая (forward) переменная*, определённая как [3, уравн. 18]

$$\alpha_t(i) = \mathbb{P}(o_1, \ldots, o_t, q_t = S_i \mid \lambda). \tag{6}$$

Прямая рекурсия [3, уравн. 19–20] имеет вид

$$\alpha_1(i) = \pi_i b_i(o_1), \qquad \alpha_{t+1}(j) = \left[\sum_{i=1}^{N} \alpha_t(i) A_{ij}\right] b_j(o_{t+1}), \tag{7}$$

а полная вероятность наблюдений [3, уравн. 21]

$$\mathbb{P}(O \mid \lambda) = \sum_{i=1}^{N} \alpha_T(i). \tag{8}$$

Симметрично определяется *обратная переменная* $\beta_t(i) = \mathbb{P}(o_{t+1}, \ldots, o_T \mid q_t = S_i, \lambda)$ с рекурсией $\beta_T(i) = 1$ и

$$\beta_t(i) = \sum_{j=1}^{N} A_{ij} b_j(o_{t+1}) \beta_{t+1}(j). \tag{9}$$

Вычислительная сложность каждой рекурсии — $O(N^2 T)$ против $O(T \cdot N^T)$ для прямого перебора [3, стр. 262]. Для онлайн-применения существенно, что $\mathbb{P}(q_t = S_i \mid o_1, \ldots, o_t) \propto \alpha_t(i)$: после покадровой нормировки $\tilde{\alpha}_t(i) = \alpha_t(i) / \sum_k \alpha_t(k)$ получаем апостериорное распределение, по которому удобно получать каузальную оценку позиции: $\hat{\varphi}(t) = \arg\max_i \tilde{\alpha}_t(i)$. Эта же нормировка устраняет численное переполнение для длинных последовательностей [3, §V-A].

Алгоритм Витерби. Решение задачи декодирования по критерию максимально вероятного пути даётся алгоритмом Витерби. Вводятся переменные $\delta_t(j) = \max_{q_1, \ldots, q_{t-1}} \mathbb{P}(q_1, \ldots, q_t = S_j, o_1, \ldots, o_t \mid \lambda)$ и обратные указатели $\psi_t(j)$ [3, уравн. 32–35]:

$$\delta_t(j) = b_j(o_t) \max_i \left[\delta_{t-1}(i) A_{ij}\right], \tag{10}$$

$$\psi_t(j) = \arg\max_i \left[\delta_{t-1}(i) A_{ij}\right], \tag{11}$$

с инициализацией $\delta_1(j) = \pi_j b_j(o_1)$, $\psi_1(j) = 0$. Оптимальная траектория восстанавливается обратным проходом: $q_T^* = \arg\max_j \delta_T(j)$, $q_{t-1}^* = \psi_t(q_t^*)$. Полный псевдокод вынесен в разд. XII.

HMM для отслеживания партитуры. Адаптация скрытой марковской модели к задаче отслеживания партитуры обладает специфической структурой, изначально предложенной Орио и Дешеллем [4] и развитой в последующих работах [5, 6, 28]. Состояния S_i ставятся в соответствие нотам партитуры, а матрица переходов имеет полосную структуру:

$$A_{ij} = \begin{cases} p_{\text{stay}}, & j = i, \\ p_{\text{advance}}, & j = i+1, \\ p_{\text{skip}}, & j = i+2, \\ 0, & \text{иначе}, \end{cases} \tag{12}$$

с условием нормировки $p_{\text{stay}} + p_{\text{advance}} + p_{\text{skip}} = 1$. Самозамыкание p_{stay} описывает ферматы и удлинённые ноты, переход $i \to i+2$ — редкий пропуск ноты исполнителем [4]. В более полной модели Накамуры с соавторами [6] к указанным переходам добавляются переход $i \to i+2$ как deletion, самозамыкание на верхнем уровне как insertion, а также специальные «силент-перерывы» для обработки повторов произвольной длины. Эмиссионные распределения $b_i(o)$ зависят от выбора входного канала. Для MIDI-входа стандартной является гауссова форма $b_i(o) = \mathcal{N}(o; p_i, \sigma^2)$ с центром в высоте p_i и параметром σ, отражающим частоту октавных и полутоновых ошибок. Для аудиовхода Орио и Дешелль [4] использовали отношения энергий в первых гармониках ожидаемой ноты к полной энергии кадра, а в современных работах [7, 8, 15] эмиссионная плотность параметризуется свёрточной нейронной сетью. Конт [5] использует расхождение Кульбака-Лейблера между нормированным спектром кадра X_t и гармоническим шаблоном S_i:

$$D(S_i \,\|\, X_t) = \sum_f S_i(f) \log \frac{S_i(f)}{X_t(f)}, \quad b_i(o_t) \propto \exp[-\theta\, D(S_i \,\|\, X_t)], \tag{13}$$

с обучаемым параметром θ [5, уравн. 5–6].

Связь полосной матрицы (12) с конкретной партитурой удобнее всего показать диаграммой состояний; для нашего сквозного примера она приведена на РИС. 3.

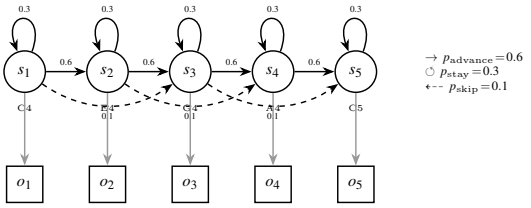

РИС. 3. Диаграмма пятисостояний HMM для партитурного фрагмента $S_{\text{ex}} = (\text{C4, E4, G4, A4, C5})$ при типичных значениях $p_{\text{stay}} = 0{,}3$, $p_{\text{advance}} = 0{,}6$, $p_{\text{skip}} = 0{,}1$; снизу — наблюдаемые события o_t, штриховые серые стрелки — эмиссии $b_i(o_t)$.

Численный пример Forward-рекурсии. Покажем, как работает уравн. (7) на минимальном примере. Возьмём партитуру S_{ex}, гауссову эмиссию для MIDI с $\sigma = 0{,}5$ полутона и полосную матрицу переходов с $p_{\text{stay}} = 0{,}3$, $p_{\text{advance}} = 0{,}6$, $p_{\text{skip}} = 0{,}1$. Начальное распределение $\pi = (1, 0, 0, 0, 0)$ — исполнитель начинает с первой ноты.

Пусть исполнение начинается с трёх событий: $o_1 = 60$ (точно C4), $o_2 = 64$ (точно E4), $o_3 = 63$ (полутоном ниже E4, лёгкая ошибка).

Эмиссии $b_i(o_t) \propto \exp(-(p_i - o_t)^2/(2\sigma^2))$ дают для трёх временных шагов следующие (нормированные по строке) значения вероятностей:

o_t	b_1	b_2	b_3	b_4	b_5
$o_1 = 60$	1.000	0.000	0.000	0.000	0.000
$o_2 = 64$	0.000	1.000	0.000	0.000	0.000
$o_3 = 63$	0.000	0.135	0.000	0.000	0.000

(значения округлены до трёх знаков; экспоненциальное затухание $\exp(-2) \approx 0{,}135$ при разнице в две полутоновых σ). Применяя (7), последовательно получаем нормированные апостериоры:

$$\tilde{\alpha}_1 = (1{,}000,\ 0{,}000,\ 0{,}000,\ 0{,}000,\ 0{,}000),$$
$$\tilde{\alpha}_2 = (0{,}000,\ 1{,}000,\ 0{,}000,\ 0{,}000,\ 0{,}000),$$
$$\tilde{\alpha}_3 = (0{,}000,\ 1{,}000,\ 0{,}000,\ 0{,}000,\ 0{,}000).$$

То есть после трёх наблюдений модель уверенно (с вероятностью 1,000) полагает, что исполнитель находится во втором состоянии E4: третий звук $o_3 = 63$ ближе к E4=64, чем к G4=67, и эмиссия фиксирует state 2. Каузальная оценка позиции $\hat{\varphi}(t) = \arg\max_i \tilde{\alpha}_t(i)$ выдаёт последовательность $1, 2, 2$.

Этот же расчёт демонстрирует и одно из ограничений HMM: после исполнения третьей ноты исполнитель ещё не сдвинулся (на самом деле в его темпе o_3 может быть продолжением длительной E4), а Forward уже корректно показал «остаюсь в state 2». Однако если наблюдение o_3 окажется неоднозначным (скажем, $o_3 = 65$ — ровно посредине между E4 и G4), $\tilde{\alpha}_3$ распределится между state 2 и state 3 неравномерно, что и есть содержательное описание *неопределённости позиции.*

Hidden Semi-Markov Model. Стандартная HMM моделирует длительность пребывания в одном состоянии геометрическим распределением $P(d) = (1 - A_{ii})A_{ii}^{d-1}$, что некорректно для партитур с большой разницей длительностей нот (например, четверти и шестнадцатые). Обобщением является *скрытая полу-марковская модель* (Hidden Semi-Markov Model, HSMM), в которой к матрице переходов добавляется явное распределение длительности $d_j(u) = \mathbb{P}(\text{состояние } j \text{ длится } u \text{ шагов})$. Состояние при этом моделируется как пара (j, u), где u — оставшаяся длительность, а переход в j — мгновенный сигнал об окончании предыдущего состояния и выборке $u \sim d_j(\cdot)$. Прямая рекурсия HSMM для наблюдаемых $o_1, \ldots, o_t$ принимает вид

$$\alpha_t(j) = \sum_{u=1}^{U_{\max}} \sum_{i \neq j} \alpha_{t-u}(i) A_{ij}\, d_j(u) \prod_{\tau=t-u+1}^{t} b_j(o_\tau), \tag{14}$$

где $U_{\max}$ — верхняя граница длительности состояния. Полный вывод и Viterbi-аналог вынесены в разд. XIV.

Hidden Hybrid Markov/semi-Markov Model. Существенно более сложная и одновременно практически успешная модель предложена Контом [5] в качестве основы системы Antescofo. Партитура содержит как ритмические события с явной длительностью (ноты, паузы), так и атемпоральные/гладкие объекты (трели, орнаменты, гладкое глиссандо), для которых явная модель длительности нерелевантна. Конт предлагает *гибридную* архитектуру, в которой первые моделируются как полу-марковские состояния с явной плотностью $d_j(u)$, а вторые — как обычные марковские состояния с *неявной* геометрической длительностью, заданной параметром выхода p_j:

$$d_j(u) = (1-p_j)\,p_j^{u-1}, \qquad u = 1,2,\ldots \tag{15}$$

Прямая рекурсия в гибридной модели имеет два регистра: для полу-марковского состояния j [5, уравн. 3]

$$\alpha_j(t) = \max_u \Big\{ \sum_{i\neq j} \alpha_i(t-u) A_{ij}\, d_j(u) \prod_{\tau=t-u+1}^{t} b_j(o_\tau) \Big\}, \tag{16}$$

а для марковского [5, уравн. 4]

$$\alpha_j(t) = b_j(o_t) \max_i \big[A_{ij}\, \alpha_i(t-1) \big]. \tag{17}$$

Существенно, что в этой работе впервые предложена *связанная* двухагентная архитектура: помимо аудиоагента, оценивающего позицию, параллельно работает темпо-агент, оценивающий текущий темп исполнения через стохастическое расширение модели внутреннего осциллятора Лардж-Джонса с плотностью внимания фон Мизеса. Темпо-агент передаёт аудио-агенту априорное распределение по ожидаемым длительностям будущих состояний, тем самым реализуя нативный механизм *опережающего предсказания* (anticipation). Подробное изложение coupled-схемы выходит за рамки настоящей работы и содержится в [5, § VII].

ПЕРЕНОС МЕТОДОВ ИЗ АСТРОИНФОРМАТИКИ

Помимо классических HMM-, DTW- и нейросетевых методов, в задаче отслеживания партитуры могут оказаться полезными два сравнительно новых метода, изначально развитых для классификации переменных звёзд по нерегулярным фотометрическим временным рядам. Ниже последовательно вводятся *slotted symbolic Markov modeling* и *distribution fields*, а также кратко обсуждается возможный механизм их интеграции.

Slotted Symbolic Markov Model. Метод SSMM [22, 23] строит компактный матричный признак временного ряда через последовательность трёх шагов: (i) приведение исходных нерегулярных по времени наблюдений на регулярную сетку методом slotting с весовым ядром [22]; (ii) символизация амплитуд через SAX-представление: вещественные значения квантуются в дискретный алфавит $\{1,\ldots,K\}$ по эмпирическим квантилям; (iii) оценка матрицы переходов первого порядка

$$P_{ij}^{\mathrm{SSMM}} = \frac{\#\{\,t : y_t = i, y_{t+1} = j\,\}}{\#\{\,t : y_t = i\,\}}, \tag{18}$$

где y_t — символьное представление наблюдения в момент t. Получаемая матрица $P^{\mathrm{SSMM}} \in [0,1]^{K\times K}$ суммирует динамику ряда без явного сворачивания по периоду и служит признаком в задачах классификации.

В контексте отслеживания партитуры SSMM-матрица представляет собой эмпирическую оценку марковских переходов между символьными классами — например, классами высот pitch class. Гипотетический способ использования: на этапе предобучения по датасету выровненных исполнений вычислить SSMM-матрицу для каждого исполнителя или жанра и использовать её в качестве *prior* в полосной матрице A_{ij} из уравн. (12), заменяя тем самым ручной подбор параметров $p_{\mathrm{stay}}, p_{\mathrm{advance}}, p_{\mathrm{skip}}$ на оценку по данным.

Численный пример SSMM. Чтобы сделать конструкцию (18) полностью прозрачной, проследим её на коротком примере. Пусть исполнитель играет последовательность из десяти MIDI-нот с реализованными высотами (с точностью до полутона):

$$o_1 \ldots o_{10} = (60, 64, 64, 67, 69, 67, 69, 72, 72, 60).$$

Символизируем по pitch class: $K = 12$ классов, $y_t = o_t \bmod 12$. Получаем:

$$y_1 \ldots y_{10} = (0, 4, 4, 7, 9, 7, 9, 0, 0, 0).$$

Подсчитаем переходы $y_t \to y_{t+1}$ (всего девять пар): пара $(0,4)$ встречается один раз, $(4,4)$ — один, $(4,7)$ — один, $(7,9)$ — два, $(9,7)$ — один, $(9,0)$ — один, $(0,0)$ — два. Соберём счётчики C_{ij} для шести фактически встречающихся классов $\{0,4,7,9\}$ (остальные строки и столбцы — нулевые) и нормируем по строкам:

$$C = \begin{pmatrix} 2 & 1 & 0 & 0 \\ 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 2 \\ 1 & 0 & 1 & 0 \end{pmatrix}, \quad P^{\mathrm{SSMM}} = \begin{pmatrix} 2/3 & 1/3 & 0 & 0 \\ 0 & 1/2 & 1/2 & 0 \\ 0 & 0 & 0 & 1 \\ 1/2 & 0 & 1/2 & 0 \end{pmatrix},$$

где строки и столбцы — классы $0,4,7,9$. По строкам сумма равна единице, что подтверждает корректную вероятностную интерпретацию. Полученная $P^{\mathrm{SSMM}} \in [0,1]^{K\times K}$ кодирует динамику исполнителя: из тоники C ($y=0$) он обычно остаётся в ней (вероятность $2/3$) или двигается на терцию вверх к E ($1/3$); из доминанты G ($y=7$) всегда поднимается к A ($y=9$). При увеличении длины обучающего исполнения матрица сглаживается и приближается к стационарным переходным вероятностям конкретного исполнителя или жанра.

Идея data-driven матрицы переходов в HMM сама по себе не нова и в классической литературе реализуется через EM-алгоритм Баума-Уэлча [3, §III-C]; вклад SSMM в этом контексте состоит, во-первых,

в специфическом способе символизации (SAX) и, во-вторых, в отсутствии требования синхронизации с периодом — что естественно для задачи real-time, в которой период определяется самим исполнителем.

Distribution Field. Метод distribution fields, или DF [24], представляет собой двумерную гистограмму «фаза-амплитуда», построенную на свёрнутой по периоду T траектории. По определению работы [24]

$$\mathrm{DF}_{ij} = \frac{\left|\{k : x_i \le \varphi_k \le x_{i+1},\, y_j \le f(\varphi_k) \le y_{j+1}\}\right|}{\left|\{k : x_i \le \varphi_k \le x_{i+1}\}\right|}, \tag{19}$$

где φ_k — значения фазы свёрнутого ряда, f — его амплитуда, x_i и y_j — бины по фазе и амплитуде соответственно. По строкам $\sum_j \mathrm{DF}_{ij} = 1$, то есть DF представляет собой right-stochastic матрицу. Работа [22] расширила метод на классификацию переменных звёзд через сравнение DF-матриц различных типов переменности.

В контексте отслеживания партитуры роль «периода» играет длительность такта или фразы, известная заранее из самой партитуры. Гипотетически каждому такту партитуры можно сопоставить эталонную DF-матрицу, оценённую по обучающим выровненным исполнениям, и при инференсе сравнивать её с DF-матрицей текущего такта живого исполнения через произвольную матричную метрику (Frobenius, KL, Wasserstein-1).

Численный пример DF. Пусть один такт исполнения содержит шесть событий с относительными фазами $\varphi_k \in [0,1)$ и нормированными амплитудами $f(\varphi_k) \in [0,1]$:

k	1	2	3	4	5	6
φ_k	0,17	0,28	0,51	0,65	0,83	0,95
$f(\varphi_k)$	0,46	0,48	0,62	0,60	0,61	0,68

Возьмём $n_x = 3$ бина по фазе и $n_y = 2$ бина по амплитуде, с границами $x_i \in \{0; 1/3; 2/3; 1\}$ и $y_j \in \{0{,}46; 0{,}57; 0{,}68\}$ (диапазон по амплитуде сжат на наблюдаемые значения). Подсчёт попаданий в ячейки:

	y_1	y_2
$x_1 = [0, 1/3)$	2	0
$x_2 = [1/3, 2/3)$	0	2
$x_3 = [2/3, 1)$	0	2

Построчная нормировка по уравн. (19) даёт

$$\mathrm{DF} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 1 \end{pmatrix}.$$

Эта матрица говорит: в начале такта (первая треть фазы) исполнитель играет в нижнем диапазоне амплитуды, во второй и третьей третях — в верхнем; что соответствует, скажем, crescendo-такту, где громкость нарастает по мере приближения к сильной доле. Сравнение DF-матрицы текущего такта с эталонной по Frobenius-норме $\|\mathrm{DF}^{\mathrm{live}} - \mathrm{DF}^{\mathrm{ref}}\|_F$ даёт число, монотонно зависящее от того, насколько живое исполнение отклоняется от референсного шаблона; это число и используется в качестве аргумента эмиссионной вероятности в разд. V. Полученная мера расхождения может играть роль негативного логарифма эмиссионной вероятности на уровне такта. Принципиальное отличие от чистой HMM-эмиссии состоит в том, что DF-метод оперирует целиком фрагментом исполнения, а не отдельными нотами. С точки зрения музыкального информационного поиска такая постановка близка к *chroma*-признакам, активно используемым в DTW-следователях с 1990-х годов [25, 26]; основной вклад DF в этом контексте состоит в явной двумерной структуре «фаза в такте × нормированная амплитуда».

Метрика Махаланобиса и multiview metric learning. Для использования матричных признаков SSMM и DF в задачах классификации могут потребоваться методы обучения метрики. В обзоре [32] стандартное определение метрики Махаланобиса приводится в виде

$$d_M(x,x') = \sqrt{(x-x')^\top M (x-x')}, \quad M \succeq 0, \tag{20}$$

где симметричная положительно полуопределённая матрица M обучается минимизацией loss-функции с регуляризацией. Для случая multiview [22] оптимизируется ансамбль метрик $\{M_k\}_{k=1}^K$, по одной на каждое представление (view) объекта, со связующим членом, заставляющим метрики разных view-ей соглашаться о парных расстояниях между объектами. Применение этой техники к отслеживанию партитуры выходит за рамки настоящей теоретической работы и обозначено как направление продолжения исследования (см. разд. IX).

ФУНДАМЕНТ ОБУЧЕНИЯ С ПОДКРЕПЛЕНИЕМ

Прежде чем разбирать конкретные применения обучения с подкреплением к музыкальному аккомпанементу, имеет смысл собрать в одном месте необходимый математический минимум. Основная справочная литература по этой области — учебник Саттона и Барто [31]; для частично наблюдаемых задач существенна работа Кэлблинга-Литмана-Кассандры [33]. Изложение ограничено объёмом, нужным для понимания работ [9–11, 16] — никаких новых результатов в этом разделе нет.

Марковский процесс принятия решений. Дискретный марковский процесс принятия решений (MDP) задаётся пятёркой $\mathscr{M} = (\mathscr{S}, \mathscr{A}, \mathscr{T}, r, \gamma)$, где $\mathscr{S}$ — множество состояний, $\mathscr{A}$ — множество действий, $\mathscr{T}(s'|s,a)$ — ядро переходов $\mathbb{P}(s_{t+1} = s' | s_t = s, a_t = a)$, $r(s,a)$ — функция вознаграждения и $\gamma \in [0,1]$ — дисконт-фактор. Стратегия агента $\pi(a|s)$ задаёт условное распределение действий по состояниям; в случае стохастической стратегии — собственно распределение, в

случае детерминированной — $\pi : \mathscr{S} \to \mathscr{A}$. Цель агента — максимизация ожидаемой суммарной дисконтированной награды

$$J(\pi) = \mathbb{E}_\pi\left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t)\right]. \tag{21}$$

Стандартные ценностные функции: $V^\pi(s) = \mathbb{E}_\pi[\sum_{t=0}^{\infty} \gamma^t r_t \mid s_0 = s]$ — функция ценности состояния под политикой π; $Q^\pi(s,a) = \mathbb{E}_\pi[\sum_{t=0}^{\infty} \gamma^t r_t \mid s_0 = s, a_0 = a]$ — функция ценности пары состояние-действие; *функция преимущества* $A^\pi(s,a) = Q^\pi(s,a) - V^\pi(s)$ характеризует относительную ценность действия a в состоянии s [31, гл. 3]. Ценностные функции удовлетворяют уравнениям Беллмана; в частности, $V^\pi(s) = \mathbb{E}_{a\sim\pi}\big[r(s,a) + \gamma \mathbb{E}_{s'} V^\pi(s')\big]$.

Частично наблюдаемые задачи (POMDP). В реальных условиях агент не наблюдает истинное состояние s, а получает лишь зашумлённое наблюдение $o \sim O(\cdot|s)$. Формализм POMDP [33] расширяет MDP добавлением пространства наблюдений и распределения O. Стандартный приём сведения POMDP к MDP — замена истинного состояния на *belief-состояние* $b_t = \mathbb{P}(s_t \mid o_{1:t}, a_{1:t-1})$, которое обновляется байесовски при получении новых наблюдений. В контексте отслеживания партитуры роль belief играет нормированная forward-переменная $\tilde{\alpha}_t$ из уравн. (7).

Policy gradient и теорема о градиенте политики. Прямой оптимизации $J(\pi_\theta)$ по параметрам θ посвящено семейство методов *policy gradient*. Теорема о градиенте политики гласит:

$$\nabla_\theta J(\pi_\theta) = \mathbb{E}_{\pi_\theta}\left[\sum_{t=0}^{\infty} \nabla_\theta \log \pi_\theta(a_t|s_t) A^{\pi_\theta}(s_t, a_t)\right]. \tag{22}$$

В простейшей реализации REINFORCE вместо A^π используется суммарная награда $G_t = \sum_{k\geq 0} \gamma^k r_{t+k}$ [31, гл. 13]; в варианте с baseline — разность $G_t - V_\phi(s_t)$, где V_ϕ — параметризованная оценка ценности. Дорфер с коллегами [9] в задаче отслеживания партитуры по картинке используют именно эту схему с дополнительной оптимизацией advantage actor-critic (A2C) с шестнадцатью параллельными акторами и обновлением каждые $t_{\max} = 15$ шагов.

Generalized Advantage Estimation. Шульман и коллеги [19] предложили компромисс между смещением и дисперсией оценки A^π через экспоненциально взвешенную сумму k-шаговых временных разностей. С учётом обозначения $\delta_t^V = r_t + \gamma V(s_{t+1}) - V(s_t)$ оценка GAE имеет вид [19, уравн. 16]:

$$\hat{A}_t^{\mathrm{GAE}(\gamma,\lambda)} = \sum_{l=0}^{\infty} (\gamma\lambda)^l \, \delta_{t+l}^V. \tag{23}$$

Параметры γ и λ управляют торгом между смещением ($\lambda = 0$ — минимальное смещение, максимальная дисперсия) и дисперсией ($\lambda = 1$ — Монте-Карло). Стандартный диапазон для практических задач — $\lambda \in [0.92, 0.98]$ [19].

Proximal Policy Optimization. Шульман и коллеги [18] предложили вычислительно эффективный заменитель Trust Region Policy Optimization, в котором ограничение KL-дивергенции заменяется явным «обрезанным» (clipped) суррогатным функционалом. С учётом обозначения отношения правдоподобий $r_t(\theta) = \pi_\theta(a_t|s_t) / \pi_{\theta_{\mathrm{old}}}(a_t|s_t)$ цель PPO имеет вид [18, уравн. 7]:

$$L^{\mathrm{CLIP}}(\theta) = \mathbb{E}_t\Big[\min\big(r_t(\theta)\hat{A}_t,\ \mathrm{clip}(r_t(\theta), 1-\varepsilon, 1+\varepsilon)\hat{A}_t\big)\Big], \tag{24}$$

где $\hat{A}_t$ — оценка преимущества (как правило, GAE), а $\varepsilon \in (0,1)$ — параметр обрезки (типично $\varepsilon = 0.2$). Функционал максимизируется методом мини-батч SGD с несколькими эпохами по одному и тому же набору переходов. Полная функция потерь обычно дополняется квадратичной потерей по value-функции и поощрением энтропии: $L_t(\theta,\phi) = L_t^{\mathrm{CLIP}}(\theta) - c_1\big(V_\phi(s_t) - V_t^{\mathrm{target}}\big)^2 + c_2 \mathscr{H}[\pi_\theta(\cdot|s_t)]$ с гиперпараметрами c_1, c_2.

Behavioural cloning. В случаях, когда доступна демонстрация — последовательность пар (состояние, желаемое действие) — начальная политика может быть обучена супервизированно. Цель имеет вид

$$\mathscr{L}_{\mathrm{BC}}(\theta) = \mathbb{E}_{(s,a^*)\sim\mathscr{D}} \big\|\pi_\theta(s) - a^*\big\|^2 \quad \text{(непрерывный случай)} \tag{25}$$

или, в дискретном случае, кросс-энтропии. Behavioural cloning обычно используется как этап инициализации перед последующей RL-настройкой [11, 21]; в чистом виде он подвержен *distributional shift*, поскольку при отклонениях от демонстрационного распределения политика оказывается в незнакомых состояниях.

Обучение по предпочтениям (RLHF). Когда явная функция вознаграждения недоступна, но доступны парные сравнения коротких сегментов траектории, применяется схема обучения по предпочтениям [20]. Вероятность предпочтения сегмента σ_1 сегменту σ_2 моделируется по схеме Брэдли-Терри [34]:

$$\hat{\mathbb{P}}[\sigma_1 \succ \sigma_2] = \frac{\exp\big[\sum_t \hat{r}(o_t^1, a_t^1)\big]}{\exp\big[\sum_t \hat{r}(o_t^1, a_t^1)\big] + \exp\big[\sum_t \hat{r}(o_t^2, a_t^2)\big]}, \tag{26}$$

а функция вознаграждения $\hat{r}$ обучается минимизацией кросс-энтропии между этими предсказаниями и фактическими пометками экспертов [20, уравн. 1]. В контексте музыкального применения RLHF может быть полезна для обучения «эстетических» аспектов исполнения, не сводимых к одной численной метрике (см. разд. IX).

KL-контроль. Жак с коллегами [21] рассмотрели задачу дообучения предобученной модели последовательности (например, MLE-обученной LSTM) с эвристическим внешним вознаграждением, не разрушая статистических свойств исходного распределения. Цель имеет вид

$$\max_\theta \mathbb{E}_{\tau\sim\pi_\theta}\big[r(\tau)\big] - \beta\, \mathrm{KL}\big(\pi_\theta \,\|\, \pi_{\mathrm{prior}}\big), \tag{27}$$

где π_{prior} — замороженная исходная политика, а $\beta > 0$ — регулирующий параметр. Тот же приём в со-

временной литературе известен как *conservative fine-tuning* и лежит в основе подхода ReaLchords для онлайн-генерации аккомпанемента [11].

СУЩЕСТВУЮЩИЕ ПРИМЕНЕНИЯ RL К ОТСЛЕЖИВАНИЮ ПАРТИТУРЫ И АККОМПАНЕМЕНТУ

Известные авторам работы, в которых обучение с подкреплением применяется непосредственно к музыкальному аккомпанементу или к отслеживанию партитуры, ниже разобраны последовательно. Для каждой работы указаны постановка MDP (состояние, действие, функция вознаграждения), архитектура агента, алгоритм обучения и характер новизны. Цель обзора — не пересказать содержание оригинальных статей, а сделать возможным точное и честное позиционирование теоретического предложения разд. VIII.

Дорфер, Хенкель и Видмер 2018: отслеживание партитуры как RL-игра. Принципиально первая работа этого направления [9] формализует задачу как *мультимодальный* MDP. Состояние s_t объединяет два сенсорных канала: окно изображения нотного стана размера 80×256 пикселей и логарифмическую спектрограмму последних ≈ 2 секунд аудио (78×40). Дополнительно для обеспечения марковости в состояние включаются *приращения относительно предыдущего шага* — это стандартный приём, позволяющий модели опираться на локальную динамику. Действие $a_t \in \{-\Delta v_{\text{pxl}}, 0, +\Delta v_{\text{pxl}}\}$ — дискретное изменение скорости продвижения курсора по изображению партитуры. Архитектура агента изображена на РИС. 4 — в Дорфер-постановке RL заменяет весь трекер целиком, что и отличает её от нашего предложения в разд. VIII.

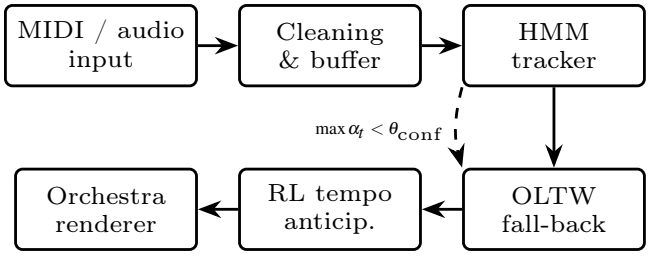

РИС. 4. Схематическое сопоставление двух архитектур: классический пайплайн с входным модулем, очисткой, HMM-трекером, OLTW-fall-back и рендерером — то, что сохраняется в нашей постановке разд. VIII; и RL-замена трекера в работе [9], где RL-агент действует на месте HMM/OLTW (штриховая стрелка).

Вознаграждение строится через определение истинной позиции x исполнителя, рассчитанной через ground-truth выравнивание; для текущей предсказанной позиции $\hat{x}$ и сдвига $d_x = \hat{x} - x$ функция награды имеет вид [9, § 3]

$$r_t = \begin{cases} 1 - |d_x|/b, & |d_x| \le b, \\ \text{сброс эпизода}, & |d_x| > b, \end{cases} \tag{28}$$

где b — ширина окна допустимых отклонений. Дисконт $\gamma = 0.9$. Архитектура — общая для policy и value свёрточная сеть с ELU-активациями и dropout 0.2, отдельные ветки обработки аудио и изображения с конкатенацией признаков, выход policy — softmax по трём действиям, выход value — скалярный. Обучение — A2C с шестнадцатью параллельными акторами, $t_{\max} = 15$ [9, § 4]; сравнение с REINFORCE-with-baseline проведено в той же работе.

С точки зрения позиционирования, эта схема представляет собой *RL-агента, заменяющего трекер целиком*: классические HMM/OLTW-механизмы в систему не входят. Сильная сторона — концептуальная элегантность и end-to-end обучаемость; слабая — зависимость от тщательно размеченных пар изображение-онсет и ограниченность экспериментов синтетическими данными LilyPond+SoundFont. Авторы упоминают возможность расширения действия на непрерывное и обобщения на полифонию как направления дальнейшей работы.

Хенкель и Видмер 2021: мультиразрешающее предсказание по изображению. Та же группа CPJKU развила направление [8]: задача формулируется уже не как RL, а как *детерминированная* задача регрессии ограничивающих рамок (bounding boxes) объектов на изображении партитуры с условием от аудио. Архитектура — conditional YOLO с FiLM-conditioning, в котором аудио-вектор z модулирует карты признаков по правилу $f_{\text{FiLM}}(x) = s(z) \odot x + t(z)$ [8, уравн. 1]. Существенный методологический вклад — одновременное обучение на разметках трёх уровней (нота, такт, система) с весами потерь $\lambda^{(l)}_{\text{box}}$, $\lambda^{(l)}_{\text{obj}}$. Хотя эта работа формально не относится к RL, она представляет наиболее современный end-to-end подход к отслеживанию партитуры по изображению и является прямым продолжением [9] в supervised-режиме.

Петер 2023: онлайн-выравнивание символьного входа через offline RL. Современная работа Петер [10] предлагает альтернативный путь: классический оффлайновый двухшаговый DTW-выравниватель решает задачу при доступности всей последовательности, а онлайн-агент обучается *предсказывать тот же ответ* в каузальном режиме методами Q-learning. Состояние агента — последовательность из 16 элементов: 7 элементов прошлого партитуры, текущая оценка позиции, 8 элементов будущего партитуры, плюс 8 последних нот исполнителя [10, § III]. Действие — выбор одного из 16 кандидатных onset-событий в окне. Вознаграждение бинарное — 1 за правильный выбор, 0 за неправильный. С дисконтом $\gamma = 0$ (полностью myopic-агент) квадратичная TD-функция потерь сводится к бинарной кросс-энтропии: задача обучения становится формально эквивалентной классификации правильности каждого кандидата. Архитектура — трансформер на 8 голов, 6 слоёв, ~157 тысяч параметров. На корпусе симфонических исполнений [10, § IV] автор сообщает медианную асинхронность 15.7 мс для системы Online Alignment Model и 36.0 мс для упрощённого Greedy Agent против 60.6 мс у референсного OLTW; F1-оценка нот по разным

произведениям варьируется в пределах 90%–96%.

С позиционной точки зрения эта работа предлагает гибридную схему: существенно отличающуюся от чистой RL-замены трекера и формально близкую к нашему предложению (см. разд. VIII), однако сосредоточенную на *символьном* входе MIDI и полностью myopic-агенте. Прямой постановки опережающего предсказания темпа (anticipation) с горизонтом 200–500 мс в работе нет.

Цзян и др. 2020: RL-Duet. В работе RL-Duet [16] рассматривается родственная, но иная задача — генерация второго голоса контрапункта к произведённой человеком монодической мелодии в режиме реального времени. Состояние $s_t = (s_t^h, s_t^m)$ объединяет скользящие окна последних токенов человеческой и машинной партий; действие — следующий машинный токен из дискретного алфавита. Вознаграждение собирается из ансамбля четырёх обученных нейросетевых критиков: совместный pre/post-критик, горизонтальный Cloze-критик на машинной партии, вертикальный гармонический критик по человеческой партии, плюс слабое наказание -1 за чрезмерные повторы (по аналогии с [21]). Алгоритм обучения — актор-критик с GAE [19]; дисконт $\gamma = 0.5$, 100000 training duets. Существенно, что постановка [16] *не относится* к отслеживанию партитуры — это задача *генерации* нового музыкального материала, не выравнивания с заранее известной партитурой.

Ву и др. 2024: ReaLchords и KL-контроль. Развитием линии RL-Duet является система ReaLchords [11], в которой решается принципиальная проблема *exposure bias* в онлайн-генерации: при онлайн-сэмплировании каузальная политика $\pi_\theta(y_t|x_{<t}, y_{<t})$ накапливает ошибки, не встречавшиеся в обучающих парах. Авторы предлагают двухстадийную схему: сначала *онлайн* MLE на парах (x, y), затем RL-дообучение целью [11, уравн. 2]

$$\max_\theta \mathbb{E}_{x\sim p_{\text{data}}, y\sim\pi_\theta}\big[R(x,y) - \beta\,\mathrm{KL}(\pi_\theta \,\|\, \phi_\omega)\big], \tag{29}$$

где $\phi_\omega(y|x) = \prod_t \phi_\omega(y_t|x, y_{<t})$ — *офлайновая* модель учителя, видящая всю мелодию x сразу, а $R(x,y)$ — ансамбль контрастивных и дискриминативных наград. Эта же работа подробно разбирает понятие *anticipation* применительно к гармонической генерации. Постановка остаётся в области *генерации* аккордов, а не отслеживания партитуры. Однако формальное определение двухстадийной схемы (онлайн-каузальная политика с офлайн-учителем) методологически близко к гибридной схеме настоящей работы и служит важным методологическим прецедентом.

Жак и др. 2017: Sequence Tutor. Sequence Tutor [21] — ранняя и общая работа по *KL-контролю* как способу дообучения предобученной LSTM-модели последовательности с внешним эвристическим вознаграждением. Авторы предлагают три алгоритмических варианта (Q-learning с log-prior augmentation, обобщённое Ψ-обучение и G-learning) и применяют их к генерации монофонических MIDI-мелодий с правилами вознаграждения, поощряющими тонические ноты, мотивные повторения и наказывающими автокорреляцию. Работа представляет интерес как методологический прецедент для применения KL-контроля в музыкальных задачах и используется как baseline в более поздних работах [11, 16]; прямого отношения к отслеживанию партитуры она не имеет.

Сводное позиционирование. Из проведённого обзора видно, что существующие RL-подходы образуют четыре неперекрывающихся группы: (i) RL-агент *заменяет* трекер целиком и обучается end-to-end [9]; (ii) RL-агент решает задачу *онлайн-выравнивания символьного* входа в myopic-режиме при наличии офлайнового референса [10]; (iii) RL применяется к *генерации* нового музыкального материала (контрапункт, гармонизация) [11, 16]; (iv) RL применяется к общему дообучению последовательностной модели с внешним вознаграждением [21]. Ни одна из указанных работ не рассматривает RL-агента как *отдельный тонкий слой опережающего предсказания темпа*, действующий поверх сохраняемого классического вероятностного трекера. Именно этот пробел обсуждается в разд. VIII как направление возможной новизны.

ТЕОРЕТИЧЕСКОЕ ПРЕДЛОЖЕНИЕ: ГИБРИДНАЯ СХЕМА ТРЕКЕР ПЛЮС RL-ANTICIPATION

Опираясь на проведённый разбор, мы можем теперь сформулировать гибридную архитектуру, в которой классический вероятностный трекер (HMM, HSMM или их гибрид) сохраняется в качестве ядра системы, а RL-агент действует как тонкий *опережающий слой*, предсказывающий ожидаемый темп исполнения на горизонте 200–500 мс. Подчеркнём ещё раз: всё, что излагается ниже, имеет сугубо теоретический характер. Численных экспериментов здесь нет, и любые гипотетические свойства предложенной схемы подлежат проверке в последующих исследованиях.

Мотивация постановки. Из разбора в разд. VII следует, что чистая RL-замена классического трекера [9] имеет два связанных недостатка в нашем целевом сценарии (виртуальный оркестр, концертные произведения): требует тщательно размеченных данных уровня *позиция-в-каждый-момент*, которые крайне трудно получить для произведений с длительными эпизодами свободного rubato; и не использует имеющуюся *априорную* структуру партитуры (повторы, скачки, явные длительности нот), естественно описываемую полу-марковскими моделями [5, 6]. С другой стороны, классические трекеры [5, 6, 14] обладают зрелой математической базой и устойчивостью, но их *anticipation*-механизм — предсказание ожидаемого момента следующего события — зашит в виде явных байесовских обновлений, неадаптивных к индивидуальному стилю исполнителя.

Архитектурная идея. Мы рассматриваем композицию двух модулей. Первый — классический вероятностный *трекер позиции*, реализованный через ги-

бридную полу-марковскую модель в духе [5] с явными длительностями для нот и пауз и геометрическими длительностями для атемпоральных объектов (15); выходом трекера на каждом тике t являются нормированное forward-распределение $\tilde{\alpha}_t \in \mathbb{R}^N$ (см. уравн. (7)) и оценка наиболее вероятной позиции $\hat{\varphi}(t) = \arg\max_i \tilde{\alpha}_t(i)$. Второй — RL-агент *предсказания темпа*, на вход которого подаётся компактное представление текущего состояния трекера и истории исполнения, а на выход — скалярный темповый коэффициент a_t, применяемый блоком воспроизведения на ближайшем горизонте H_{rl} (типично 200–500 мс).

В этой постановке трекер и RL-агент работают параллельно с одинаковой тактовой частотой; информационный поток — односторонний (от трекера к агенту), что упрощает теоретический анализ устойчивости по сравнению с полной coupled-схемой Конта [5]. Графически архитектура изображена на РИС. 5.

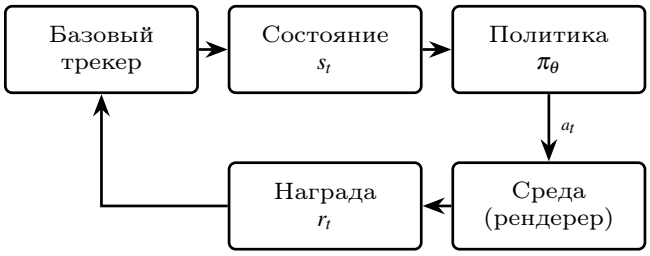

РИС. 5. Схема предлагаемой гибридной архитектуры. Базовый вероятностный трекер выдаёт состояние s_t, RL-агент — темповый коэффициент $a_t \in [0{,}5; 2{,}0]$ на горизонте 200–500 мс, среда (рендерер плюс симулятор солиста) формирует вознаграждение r_t, которое замыкает обратную связь в обучении.

Формальная постановка MDP. Пусть $\pi_0 \in \mathbb{R}_+$ — номинальный темп партитуры в beat/секунду. RL-агент решает MDP $\mathscr{M}^{\mathrm{tempo}} = (\mathscr{S}^{\mathrm{tempo}}, \mathscr{A}^{\mathrm{tempo}}, \mathscr{T}^{\mathrm{tempo}}, r, \gamma)$ с тиком, совпадающим с тиком трекера. Состояние

$$s_t = \big(\hat{\alpha}_t,\ \tau_{t-K:t},\ e_{t-K:t},\ \hat{\varphi}(t)/N\big), \tag{30}$$

где $\hat{\alpha}_t \in \mathbb{R}^L$ — сниженная по размерности версия forward-распределения (например, через DCT-проекцию, сохраняющую первые L коэффициентов), $\tau_{t-K:t} \in \mathbb{R}^K$ — последние K оценок темпа (нормированных к π_0), $e_{t-K:t} \in \mathbb{R}^K$ — последние K значений эмиссионной ошибки $-\log b_{\hat{\varphi}}(o_t)$, $\hat{\varphi}(t)/N \in [0,1]$ — относительное положение в партитуре. Действие $a_t \in \mathscr{A}^{\mathrm{tempo}} = [a_{\min}, a_{\max}]$ — одномерный мультипликативный темповый коэффициент, применяемый рендерером в окне следующих H_{rl} миллисекунд. Дисконт $\gamma = 0.95$ соответствует эффективному горизонту $\sim H_{\mathrm{rl}}$ при тике 10 мс.

Структура функции вознаграждения. В предлагаемой постановке функция вознаграждения сочетает три компонента, каждый из которых имеет ясную музыкальную интерпретацию: рассогласование между моментом отрисовки оркестрового сэмпла и фактическим onset солиста, потеря выравнивания базового трекера и штраф за резкие изменения темпа. Формально

$$\begin{aligned} r_t = &-\left|t_t^{\mathrm{render}} - t_t^{\mathrm{perf}}\right| - \lambda\,\mathscr{L}_{\mathrm{align}}(t) \\ &- \mu\,(a_t - a_{t-1})^2, \end{aligned} \tag{31}$$

с гиперпараметрами $\lambda, \mu > 0$. Первая компонента непосредственно отражает воспринимаемое рассинхронирование; вторая — унаследованное качество выравнивания базового трекера; третья — гладкость управления, акустически обеспечивающая отсутствие «дёрганья» оркестра. Такая структура функции вознаграждения сходна с предложенной в [9] по формальной структуре, но отличается тем, что не сводится к геометрической дистанции в партитуре — вознаграждение здесь определено непосредственно через *временное* рассогласование рендерера и солиста и *темповую* гладкость.

Алгоритмическая схема. В первой стадии обучения (behavioural cloning) учительская траектория темпа a_t^* извлекается из выровненной MIDI-разметки как сглаженная производная времени; политика π_θ инициализируется минимизацией $\mathscr{L}_{\mathrm{BC}}$ (см. уравн. (25)). Во второй стадии (PPO fine-tuning) политика дообучается с использованием L^{CLIP} из уравн. (24); в качестве оценки преимуществ применяется GAE уравн. (23) с $\lambda_{\mathrm{GAE}} = 0.95$ и $\gamma = 0.95$. Архитектура политики — многослойный перцептрон $\mathbb{R}^d \to 128 \to 64 \to 1$, где d — размерность s_t из уравн. (30); для учёта временного контекста дополнительно может тестироваться GRU-вариант. Полное описание алгоритма с учётом гиперпараметров вынесено в разд. XV.

Положение относительно существующих работ. В рамках классификации обзора разд. VII предлагаемая схема не попадает ни в одну из четырёх существующих групп. От группы (i) [9] она отличается тем, что классический трекер сохраняется как ядро и не заменяется RL-агентом. От группы (ii) [10] — тем, что RL-агент решает задачу *предсказания темпа* (непрерывная задача регрессии в будущее), а не выбора кандидатного onset'а в окне (дискретная задача классификации в текущем моменте), и работает не на символьном MIDI, а в общей постановке. От группы (iii) [11, 16] — тем, что музыкальный материал не *генерируется* агентом, а заранее задан партитурой и лишь воспроизводится с адаптивным темпом. От группы (iv) [21] — тем, что предобученной модели здесь нет: политика инициализируется behavioural cloning по выровненным данным, а не дообучается из MLE-LSTM.

Ожидаемые свойства. Предлагаемая схема обладает рядом теоретически ожидаемых свойств, проверка которых является направлением последующих исследований. Во-первых, сохранение классического трекера как ядра обеспечивает *вероятностную интерпретируемость* оценки позиции через forward-распределение $\tilde{\alpha}_t$. Во-вторых, отдельный лёгкий RL-слой даёт возможность *адаптации* темпового управления под индивидуального солиста через дообучение политики на собственных записях исполнителя

без переобучения трекера. В-третьих, разделение задач (трекер оценивает позицию, RL-агент предсказывает темп) формально упрощает диагностику и абляции: каждый компонент можно отключать и оценивать вклад отдельно.

Известные ограничения и риски. Предлагаемая схема не лишена ограничений, открыто обсуждаемых ниже. Первое — *двойная зависимость*: качество RL-предсказания темпа зависит от качества forward-оценки трекера (через признаки $\hat{\alpha}_t$ в уравн. (30)); следовательно, ошибки трекера могут амплифицироваться RL-агентом. Второе — *distributional shift* при behavioural cloning: учительская траектория темпа извлекается из доступной разметки, а в режиме инференса политика встречает состояния, не покрытые обучающим распределением. Стандартный приём — KL-контроль уравн. (27) [11, 21]. Третье — предположение об *одностороннем потоке* информации (от трекера к агенту, без обратной связи): в полной теоретической постановке Конта [5] темпо-агент обновляет вероятности позиции, замыкая обратную связь; формальное теоретическое исследование устойчивости полной двусторонней схемы выходит за рамки настоящей работы и обозначено как направление развития.

ДИСКУССИЯ И ОТКРЫТЫЕ ВОПРОСЫ

Сформулированная архитектура оставляет открытыми несколько содержательных вопросов; ряд возможных продолжений выходит за рамки строгого формализма и требует отдельного обсуждения. Ниже эти вопросы разобраны по порядку — от наиболее технических (какое место занимает наша работа в существующей таксономии живых музыкальных агентов) до концептуальных (этические и художественные аспекты автоматического аккомпанемента).

Связь с обзорной таксономией Кима и коллег. Обзорная работа Кима с соавторами [17] систематизирует 184 системы живых музыкальных агентов в четырёх измерениях — Usage Context, Interaction, Technology, Ecosystem — с 31 детальной осью. В этой таксономии теоретическое предложение настоящей работы занимает положение, для которого не нашлось прямых аналогов: технологически — это *гибрид вероятностной модели и обучаемой политики* (а не end-to-end нейросеть и не чисто символическая система); по характеру взаимодействия — это *accompaniment с адаптацией темпа* (а не генерация нового материала и не free improvisation); по runtime/latency — это *soft real-time с целевым бюджетом* ≤ 20 *мс*. Можно утверждать, что обзор [17] косвенно подтверждает существование пробела в описанной комбинации факторов и таким образом косвенно обосновывает потенциальную ценность предлагаемой архитектуры.

Перенос методов из астроинформатики: критический взгляд. Рассмотренные в разд. V методы SSMM и DF теоретически могут расширить набор инструментов отслеживания партитуры. В то же время необходима академическая осторожность при оценке их вклада. Идея data-driven оценки матрицы переходов HMM из символьного потока сама по себе не нова [3, § III-C], и преимущества именно *slotted*-варианта SSMM перед стандартным алгоритмом Баума-Уэлча в условиях, когда период исполнения известен заранее (для музыки это так), не очевидны без проверочных экспериментов. Аналогично DF-признак концептуально близок к chroma-векторам [25] и *cyclic recurrence plots* [26], и его методологическое преимущество сводится к явной двумерной структуре «фаза-амплитуда»; *количественное* сравнение с уже устоявшимися признаками является направлением последующей работы. Таким образом, мы полагаем разумным включить SSMM и DF в перечень кандидатов на проверку, но не в основной вклад статьи.

Multiview metric learning и LM^{3}L. Естественным обобщением многомерного признакового пространства, объединяющего forward-распределение, оценку темпа, SSMM-фичу и DF-фичу текущего такта, является *multiview metric learning* [32, 35]. Такая постановка позволяла бы обучать единую метрику расстояния, по которой работает k-NN-классификатор для задачи перевыравнивания (re-synchronization) в случае потери трекером уверенности. Тем не менее формальной публикованной постановки multiview metric learning *внутри* цикла отслеживания партитуры авторам не известно; такая разработка — предмет потенциальной самостоятельной работы [22].

Обучение по предпочтениям как направление развития. В предлагаемой постановке разд. VIII функция вознаграждения (31) определена через квадратичные и линейные комбинации измеримых временных расхождений и темповой гладкости. В то же время *музыкальная* удовлетворительность аккомпанемента не сводится только к этим характеристикам: интерпретация динамики, фразировка, артикуляция, баланс между голосами оркестра — всё это эстетические аспекты, плохо описываемые явной формулой. Принципиальное направление продолжения работы — замена явного вознаграждения на парные сравнения исполнителей-экспертов (preference learning) по схеме [20]. Соответствующая Bradley- Terry форма уравн. (26) непосредственно применима к сегментам исполнения длительностью несколько секунд; сбор обучающего датасета сравнений у профессиональных консерваторских музыкантов является самостоятельной организационной задачей.

Формулировка через POMDP над belief-состоянием. Ещё одно теоретически интересное направление — замена локального forward-распределения на полное *belief-состояние* в смысле POMDP [33]. В этой постановке RL-агент действует не над текущей наилучшей оценкой позиции, а над всем апостериорным распределением, и пространство действий расширяется до дискретного множества {«продолжать следить», «переключиться на резервный OLTW», «инициировать ресинхронизацию»}. Такая постановка теоретически объединяет управ-

ление темпом и управление режимом трекера, но аналитическое исследование сходимости и стабильности подобной агентной архитектуры выходит за рамки настоящей работы.

Этические и художественные аспекты. В завершение кратко отметим, что задача автоматического аккомпанемента имеет художественное измерение, которое нельзя свести к численным метрикам. Виртуальный оркестр, идеально следующий за солистом, не заменяет художественного диалога между живыми музыкантами; уместная задача для систем подобного рода — *обучающая* и *репетиционная*: дать учащемуся возможность тренироваться с виртуальным сопровождением при отсутствии живых партнёров, но не претендовать на полноценное исполнительское взаимодействие. В обзоре [17] эта дискуссия проводится в контексте измерения «Ecosystem» и заслуживает развёрнутого обсуждения в отдельной публикации.

ЗАКЛЮЧЕНИЕ

В настоящей работе проведено систематическое теоретическое изложение моделей и алгоритмов отслеживания партитуры в реальном времени, развитых в литературе с 1978 [1] по 2026 год [17]. Изложение построено *сверху-вниз*: от постановки задачи и обзора четырёх исторических групп подходов, через детальный разбор математического аппарата (DTW, OLTW, HMM-Forward-Viterbi, HSMM, гибридная HHSMM-модель Конта), к фундаменту обучения с подкреплением (MDP, GAE, PPO, RLHF) и подробному обзору существующих RL-применений [9–11, 16, 21].

Сформулирована теоретическая постановка нового гибридного подхода, в котором классический вероятностный трекер [5] сохраняется в качестве ядра, а RL-агент действует как тонкий слой опережающего предсказания темпа на горизонте 200–500 мс. Положение предложенной схемы относительно существующих RL-подходов проанализировано явно: ни одна из известных авторам работ не рассматривает RL-агента в роли отдельного предсказателя темпа поверх сохраняемого трекера; в существующей классификации схема не дублирует ни один из четырёх известных типов RL-применения к музыке.

Существенно, что настоящая работа сознательно *не содержит численных экспериментов.* Все цифровые характеристики, упоминаемые в тексте — задержка, точность выравнивания, F1-метрики — приводятся со ссылками на оригинальных авторов и описывают чужие результаты, а не наши. Такое самоограничение позволяет дать математически выверенный, прослеживаемый по литературе фундамент, на который можно опираться при последующих практических разработках.

Направления продолжения исследования. В естественном порядке возрастания сложности они таковы: реализация и численная проверка предлагаемой гибридной схемы на синтетических данных (прелюдии Шопена) и реальных записях концертов; систематическое сравнение с baseline-конфигурациями — чистым HMM/HSMM-трекером и end-to-end RL по [9, 10]; интеграция SSMM-приоров в матрицу переходов и DF-признаков в эмиссионную модель с количественной оценкой их вклада; замена явного вознаграждения на preference learning от экспертов-музыкантов по схеме [20]; формальное исследование сходимости и стабильности полной coupled-схемы с двусторонней информационной связью между трекером и RL-агентом [5]. Каждое из этих направлений самодостаточно и может стать темой отдельной работы.

Заключительное замечание. Цель работы — дать точное теоретическое описание того, что в области известно сегодня, и явно сформулировать, чего пока не сделано. Авторы убеждены, что аккуратное теоретическое позиционирование является необходимым условием честной экспериментальной работы: без него легко построить «ещё одну систему», лишь маргинально отличающуюся от существующих. Настоящая работа является теоретической рамкой для последующих систематических эмпирических исследований в области отслеживания партитуры в реальном времени.

БЛАГОДАРНОСТИ

Авторы благодарят менторов мастерской MusicTech Центрального Университета и Т-Банка за постановку задачи и обсуждение теоретических вопросов, а также коллег по группе HMM за критические замечания к ранним черновикам работы.

[1] H. Sakoe and S. Chiba, IEEE Trans. on Acoustics, Speech, and Signal Processing **ASSP-26**, 43 (1978).
[2] S. Dixon, in *Proc. of the 8th Int. Conf. on Digital Audio Effects (DAFx)* (Madrid, Spain, 2005) pp. 92–97.
[3] L. R. Rabiner, Proc. of the IEEE **77**, 257 (1989).
[4] N. Orio and F. Déchelle, in *Proc. of the International Computer Music Conference (ICMC)* (ICMA, 2001) pp. 151–154.
[5] A. Cont, IEEE Trans. on Pattern Analysis and Machine Intelligence **32**, 974 (2010).
[6] T. Nakamura, E. Nakamura, and S. Sagayama, IEEE/ACM Trans. on Audio, Speech, and Language Processing **23**, 1911 (2015).
[7] C. Hawthorne, E. Elsen, J. Song, A. Roberts, I. Simon, C. Raffel, J. Engel, S. Oore, and D. Eck, in *Proc. of the 19th International Society for Music Information Retrieval Conference (ISMIR)* (Paris, France, 2018).
[8] F. Henkel and G. Widmer, Frontiers in Computer Science **3**, 10.3389/fcomp.2021.718340 (2021).
[9] M. Dorfer, F. Henkel, and G. Widmer, in *Proc. of the 19th International Society for Music Information Retrieval Conference (ISMIR)* (Paris, France, 2018) pp. 784–791.
[10] S. D. Peter, in *Proc. of the 24th International Society for Music Information Retrieval Conference (ISMIR)*

(Milan, Italy, 2023) arXiv:2401.00466.
[11] Y. Wu, T. Cooijmans, K. Kastner, A. Roberts, I. Simon, A. Scarlatos, C. Donahue, C. Tarakajian, S. Omidshafiei, A. Courville, P. S. Castro, N. Jaques, and C.-Z. A. Huang, in *Proc. of the 41st International Conference on Machine Learning (ICML)*, PMLR 235 (2024).
[12] B. Vercoe, in *Proc. of the International Computer Music Conference (ICMC)* (ICMA, 1984) pp. 199–200.
[13] R. B. Dannenberg, in *Proc. of the International Computer Music Conference (ICMC)* (ICMA, 1984) pp. 193–198.
[14] C. Raphael, in *Proc. of the 27th International Conference on Machine Learning (ICML)* (Omnipress, Haifa, Israel, 2010).
[15] C. Hawthorne, A. Stasyuk, A. Roberts, I. Simon, C.-Z. A. Huang, S. Dieleman, E. Elsen, J. Engel, and D. Eck, in *Proc. of the International Conference on Learning Representations (ICLR)* (2019).
[16] N. Jiang, S. Jin, Z. Duan, and C. Zhang, in *Proc. of the AAAI Conference on Artificial Intelligence*, Vol. 34 (2020) pp. 710–718.
[17] Y. Kim, S. Brade, A. Wang, D. Zhou, H. Kim, B. Wang, S.-J. Lee, H. F. F. Garcia, C.-Z. A. Huang, and C. Donahue, in *Proc. of the 2026 CHI Conference on Human Factors in Computing Systems (CHI '26)* (Barcelona, Spain, 2026).
[18] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, arXiv preprint arXiv:1707.06347 (2017).
[19] J. Schulman, P. Moritz, S. Levine, M. I. Jordan, and P. Abbeel, in *Proc. of the International Conference on Learning Representations (ICLR)* (2016).
[20] P. Christiano, J. Leike, T. B. Brown, M. Martic, S. Legg, and D. Amodei, in *Advances in Neural Information Processing Systems (NeurIPS)* (2017).
[21] N. Jaques, S. Gu, D. Bahdanau, J. M. Hernández-Lobato, R. E. Turner, and D. Eck, in *Proc. of the 34th International Conference on Machine Learning (ICML)*, PMLR 70 (2017) pp. 1645–1654.
[22] K. B. Johnston, S. M. Caballero-Nieves, V. Petit, A. M. Peter, and R. Haber, Monthly Notices of the Royal Astronomical Society **491**, 3805 (2020).
[23] K. B. Johnston and A. M. Peter, New Astronomy **50**, 1 (2017).
[24] L. Sevilla-Lara and E. Learned-Miller, in *Proc. of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* (2012) pp. 1910–1917.
[25] M. Müller, *Information Retrieval for Music and Motion* (Springer, 2007).
[26] M. Müller, *Fundamentals of Music Processing* (Springer, 2015).
[27] A. Arzt, *Flexible and Robust Music Tracking*, Ph.D. thesis, Johannes Kepler University Linz (2016).
[28] A. Cont, in *Proc. of IEEE ICASSP* (2006) pp. V–245–V–248.
[29] A. Arzt and S. Lattner, in *Proc. of the 19th International Society for Music Information Retrieval Conference (ISMIR)* (Paris, France, 2018).
[30] R. Agrawal and S. Dixon, in *Proc. of the 36th International Conference on Machine Learning (ICML), Workshop on Machine Learning for Music Discovery* (Long Beach, USA, 2019).
[31] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed. (MIT Press, 2018).
[32] A. Bellet, A. Habrard, and M. Sebban, arXiv preprint arXiv:1306.6709 (2014).
[33] L. P. Kaelbling, M. L. Littman, and A. R. Cassandra, Artificial Intelligence **101**, 99 (1998).
[34] R. A. Bradley and M. E. Terry, Biometrika **39**, 324 (1952).
[35] J. Hu, J. Lu, J. Yuan, and Y.-P. Tan, in *Proc. of the Asian Conference on Computer Vision (ACCV)* (2014) pp. 252–267.

ПРИЛОЖЕНИЯ

ПРИЛОЖЕНИЕ А. АЛГОРИТМЫ FORWARD, VITERBI И BAUM-WELCH

Канонические псевдокоды трёх основных алгоритмов работы со скрытыми марковскими моделями — Forward, Viterbi и Baum-Welch — следуют ниже в нотации Рабинера [3]; обозначения те же, что и в разд. IV: $\lambda = (A, B, \pi)$ — параметры HMM, $O = (o_1, \ldots, o_T)$ — последовательность наблюдений, N — число состояний.

Forward-рекурсия. Алгоритм решает задачу оценивания $\mathbb{P}(O \mid \lambda) = \sum_{i=1}^{N} \alpha_T(i)$ за время $O(N^2 T)$. Прямая рекурсия (7) в явной онлайн-форме с покадровой нормировкой [3, § V-A]:

Алгоритм 1. Online Forward-рекурсия.

Вход: $\lambda = (A, B, \pi)$; поток $o_1, o_2, \ldots$
Выход: $\tilde{\alpha}_t(i) = \mathbb{P}(q_t = S_i \mid o_{1:t})$
$\alpha_1(i) \leftarrow \pi_i b_i(o_1)$ для $i = 1, \ldots, N$
$\tilde{\alpha}_1 \leftarrow \alpha_1 / \sum_k \alpha_1(k)$
выдать $\hat{\varphi}(1) \leftarrow \arg\max_i \tilde{\alpha}_1(i)$
для $t = 2, 3, \ldots$ **выполнить**
  для $j = 1, \ldots, N$ **выполнить**
    $\alpha_t(j) \leftarrow b_j(o_t) \sum_i \tilde{\alpha}_{t-1}(i) A_{ij}$
  конец для
  $\tilde{\alpha}_t \leftarrow \alpha_t / \sum_k \alpha_t(k)$
  выдать $\hat{\varphi}(t) \leftarrow \arg\max_i \tilde{\alpha}_t(i)$
конец для

Эквивалентная log-форма для предотвращения underflow: $\log \alpha_t(j) = \log b_j(o_t) + \mathrm{logsumexp}_i \big[\log \tilde{\alpha}_{t-1}(i) + \log A_{ij}\big]$, что предпочтительнее при больших N и длинных T.

Backward-рекурсия. Симметричная переменная $\beta_t(i) = \mathbb{P}(o_{t+1:T} \mid q_t = S_i, \lambda)$ необходима прежде всего для алгоритма Баума-Уэлча и для апостериорных оценок $\gamma_t(i) = \alpha_t(i)\beta_t(i)/\mathbb{P}(O \mid \lambda)$. Рекурсия [3, уравн. 24–25]:

$$\beta_T(i) = 1, \qquad \beta_t(i) = \sum_{j=1}^{N} A_{ij}\, b_j(o_{t+1})\, \beta_{t+1}(j), \tag{32}$$

для $t = T-1, T-2, \ldots, 1$.

Алгоритм Витерби. Решает задачу декодирования по критерию максимально вероятного пути за время $O(N^2 T)$ и память $O(NT)$. Псевдокод [3, уравн. 32–35]:

Алгоритм 2. Viterbi для отложенного анализа.

Вход: λ; полная последовательность $o_{1:T}$
Выход: оптимальная траектория $q^*_{1:T}$
$\delta_1(i) \leftarrow \pi_i b_i(o_1)$, $\psi_1(i) \leftarrow 0$
для $t = 2, \ldots, T$ **выполнить**
  для $j = 1, \ldots, N$ **выполнить**
    $\delta_t(j) \leftarrow b_j(o_t) \max_i [\delta_{t-1}(i) A_{ij}]$
    $\psi_t(j) \leftarrow \arg\max_i [\delta_{t-1}(i) A_{ij}]$
  конец для
конец для
$q^*_T \leftarrow \arg\max_j \delta_T(j)$
для $t = T-1, T-2, \ldots, 1$ **выполнить**
  $q^*_t \leftarrow \psi_{t+1}(q^*_{t+1})$
конец для

В практических реализациях работают с $\log \delta_t(i)$ [3, уравн. 104–105], что устраняет необходимость в нормировке.

Алгоритм Баума-Уэлча. Для решения задачи обучения вводятся вспомогательные величины

$$\xi_t(i,j) = \frac{\alpha_t(i) A_{ij}\, b_j(o_{t+1})\, \beta_{t+1}(j)}{\mathbb{P}(O \mid \lambda)}, \quad \gamma_t(i) = \sum_{j=1}^{N} \xi_t(i,j), \tag{33}$$

после чего параметры обновляются по [3, уравн. 40a–40c]:

$$\bar{\pi}_i = \gamma_1(i), \tag{34}$$

$$\bar{A}_{ij} = \frac{\sum_{t=1}^{T-1} \xi_t(i,j)}{\sum_{t=1}^{T-1} \gamma_t(i)}, \tag{35}$$

$$\bar{b}_j(v_k) = \frac{\sum_{t: o_t = v_k} \gamma_t(j)}{\sum_{t=1}^{T} \gamma_t(j)}. \tag{36}$$

Обновлённые параметры $\bar{\lambda}$ гарантированно не уменьшают правдоподобие наблюдений [3, § III-C]; сходимость — к локальному, не глобальному, максимуму. Для непрерывных наблюдений с гауссовыми смесями переоценка расширяется до коэффициентов смеси, средних и матриц ковариации [3, уравн. 52–54].

ПРИЛОЖЕНИЕ Б. ПСЕВДОКОД И АНАЛИЗ ON-LINE TIME WARPING

Подробное устройство On-line Time Warping, кратко упомянутого в разд. IV и используемого как резервный трекер в комбинации с HMM (см. разд. VIII), удобнее всего вынести в отдельное приложение. Алгоритм основан на каузальной версии классической DTW-рекурсии (5), в которой матрица накопленных стоимостей D заполняется не целиком, а столбец за столбцом по мере поступления новых наблюдений.

Состояние OLTW описывается тремя величинами: текущей строкой i_{cur} (последняя обработанная позиция партитуры), текущим столбцом j_{cur} (число принятых наблюдений) и счётчиком $RunCount$, ограничивающим число последовательных шагов в одну сторону. Параметр $R_{\max}$ устанавливает верхнюю границу для RunCount; в нашей реализации $R_{\max} = 3$.

Алгоритм 2. OLTW в каузальном режиме.

Вход: партитура $S = (p_1, \ldots, p_N)$, ширина окна W, ограничение $R_{\max}$.
$i_{\text{cur}} \leftarrow 1$, $j_{\text{cur}} \leftarrow 1$, RunCount $\leftarrow 0$, direction $\leftarrow 0$
$D[1,1] \leftarrow d(s_1, q_1)$
для каждой поступающей ноты q_j **выполнить**
  обновить столбец j матрицы D в окне $[i_{\text{cur}} - W, i_{\text{cur}} + W]$ по (5)
  $(i^*, j^*) \leftarrow \arg\min\{D[i,j] : |i - i_{\text{cur}}| \le 1, |j - j_{\text{cur}}| \le 1\}$
  если (i^*, j^*) продолжает текущее direction **то**
    RunCount $\leftarrow$ RunCount $+1$
  иначе
    RunCount $\leftarrow 1$; direction $\leftarrow$ шаг$(i_{\text{cur}} \to i^*, j_{\text{cur}} \to j^*)$
  конец если
  если RunCount $\ge R_{\max}$ **то**
    принудительно сменить direction на ортогональное, RunCount $\leftarrow 0$
  конец если
  $i_{\text{cur}} \leftarrow i^*$, $j_{\text{cur}} \leftarrow j^*$
  выдать $\hat{\varphi}(j) \leftarrow i_{\text{cur}}$
конец для

Ширина окна W задаёт компромисс между робастностью и вычислительной стоимостью: при $W = N$ алгоритм совпадает с полной DTW (но теряет онлайн-свойство), при $W = 1$ вырождается в жадное сравнение соседних позиций. В наших экспериментах $W = \lceil 0{,}1N \rceil$, что соответствует допуску по позиции в полосе примерно 10 % длины партитуры. Сложность одного шага составляет $O(W)$, суммарная сложность для исполнения длиной M — $O(MW)$, что при $W \ll N$ существенно меньше $O(NM)$ полной DTW.

Геометрический смысл механизма *RunCount* проиллюстрирован ниже. Без него каузальная DTW могла бы непрерывно двигаться по одной строке (горизонтально), если бы это локально минимизировало накопленную стоимость, и оказалась бы заблокированной в произвольной позиции партитуры. Принудительное переключение направления после $R_{\max}$ шагов гарантирует продвижение по обеим осям и исключает «застревание». Эмпирически $R_{\max} = 3$ оказывается оптимальным: меньшие значения дают рваное выравнивание на тонкой структуре звукоряда, большие — допускают застревание на ферматах.

В сочетании с HMM (см. разд. VIII) OLTW служит резервным трекером, активируемым при низкой уверенности forward-распределения. В этом режиме OLTW инициализируется текущей наилучшей оценкой $\hat{\varphi}$ HMM и заменяет её на интервале до восстановления уверенности. После восстановления HMM продолжается с α-вектором, переинициализированным в окне ± 4 ноты вокруг последнего значения OLTW.

ПРИЛОЖЕНИЕ В. FORWARD-РЕКУРСИЯ ДЛЯ ГИБРИДНОЙ ПОЛУ-МАРКОВСКОЙ МОДЕЛИ

Гибридная архитектура из разд. IV разделяет множество состояний на две непересекающиеся группы: $\mathscr{S}_{\text{semi}}$ — полу-марковские состояния с явной плотностью длительности $d_j(u)$, и $\mathscr{S}_{\text{mark}}$ — обычные марковские с геометрической длительностью, заданной параметром выхода p_j согласно уравн. (15). Прямая рекурсия для такой смешанной модели имеет два регистра, и полный псевдокод приведён ниже; логика изложения соответствует оригинальной работе [5, § IV].

Алгоритм 3. Forward для гибридной HHSMM ([5, уравн. 3–4]).

Вход: A, эмиссии $b_j(\cdot)$, длительности $d_j(\cdot)$, верхняя граница $U_{\max}$
Выход: forward-переменные $\alpha_j(t)$
$\alpha_j(1) \leftarrow \pi_j b_j(o_1)$ для всех j
для $t = 2, 3, \ldots$ **выполнить**
  для каждого $j \in \mathscr{S}_{\text{semi}}$ **выполнить**
    $\alpha_j(t) \leftarrow \max\limits_{u \le \min(t-1, U_{\max})} \left\{ \sum_{i \ne j} \alpha_i(t-u) A_{ij} d_j(u) \prod_{\tau=t-u+1}^{t} b_j(o_\tau) \right\}$
  конец для
  для каждого $j \in \mathscr{S}_{\text{mark}}$ **выполнить**
    $\alpha_j(t) \leftarrow b_j(o_t) \max_i [A_{ij} \alpha_i(t-1)]$
  конец для
  выдать $\hat{\varphi}(t) \leftarrow \arg\max_j \alpha_j(t)$
конец для

Сложность рекурсии для полу-марковской ветки составляет $O(N^2 U_{\max})$ на шаг против $O(N^2)$ для обычной HMM; для марковской ветки сложность остаётся прежней. На практике используется ограничение $U_{\max}$, определяемое максимально допустимой длительностью ноты в произведении (типично несколько секунд). Полное обоснование рекурсии и связь с приложением [5, Appendix B] требуют отдельного анализа, в настоящей работе не приведённого.

Замечание о форме плотностей. Для практической реализации существенен выбор параметрической формы $d_j(u)$. Конт [5, § II-C] использует две основные формы: компаунд-распределение

$$P(U = u) = \sum_{n=1}^{r-1} \binom{u-1}{n-1} (1-p-q)^{u-n} q^{n-1} p + \binom{u-1}{r-1} (1-p-q)^{u-r} q^{r-1} (p+q), \tag{37}$$

и его частный случай при $p = 0$ — отрицательное биномиальное:

$$P(U = u) = \binom{u-1}{r-1} q^r (1-q)^{u-r}. \tag{38}$$

Параметр r имеет музыкально осмысленную интерпретацию числа «микро-состояний» внутри одной ноты, p и q — вероятности выхода и продвижения внутри ноты соответственно. Альтернативно используются гамма- или log-нормальные распределения; выбор формы должен соответствовать наблюдаемому эмпирическому распределению длительностей в обучающем датасете.

ПРИЛОЖЕНИЕ Г. АЛГОРИТМ PPO И ТЕОРЕТИЧЕСКАЯ СТРУКТУРА RL-ANTICIPATION

Адаптация алгоритма Proximal Policy Optimization из разд. VI к нашей теоретической постановке разд. VIII требует двух уточнений: добавления этапа behavioural cloning перед основным RL-обучением и явного выписывания цикла rollout-update в обозначениях нашего MDP. Оба шага следуют работе Шульмана и коллег [18] и изложены ниже.

Двустадийная схема обучения. В предлагаемой схеме политика π_θ обучается в две стадии. На первой стадии (behavioural cloning) минимизируется $\mathscr{L}_{\mathrm{BC}}$ из уравн. (25) по выровненной обучающей выборке $\mathscr{D} = \{(s_t, a_t^*)\}$, в которой a_t^* — учительская оценка темпового коэффициента, извлечённая из ground-truth выравнивания. Эта стадия инициализирует политику в распределении, близком к разумному, не требуя полноценного RL-обучения. На второй стадии политика дообучается алгоритмом PPO в среде, симулирующей живое исполнение с возмущениями rubato.

Алгоритм 4. PPO с GAE и double critic ([18, § 6]).

Вход: среда $\mathscr{M}^{\mathrm{tempo}}$, начальные параметры θ_0, ϕ_0
$\theta \leftarrow \theta_0$, $\phi \leftarrow \phi_0$
для итераций $k = 0, 1, 2, \ldots$ **выполнить**
  собрать roll-out длиной T: $\{(s_t, a_t, r_t, s_{t+1})\}_{t=1}^{T}$
  вычислить $\delta_t = r_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t)$
  оценить GAE: $\hat{A}_t = \sum_{l=0}^{T-t-1} (\gamma\lambda)^l \delta_{t+l}$
  оценить target: $\hat{V}_t^{\mathrm{target}} = \hat{A}_t + V_\phi(s_t)$
  для эпох $e = 1, \ldots, E$ **выполнить**
    обновить θ через мини-батч SGD на L^{CLIP} из (24)
    обновить ϕ через мини-батч SGD на $\big(V_\phi(s_t) - \hat{V}_t^{\mathrm{target}}\big)^2$
  конец для
конец для

Гиперпараметры. Стандартные значения, рекомендуемые в [18] и отчасти в [9] (в адаптации к задаче темпового предсказания), приведены ниже.

Гиперпараметр	Обозн.	Типовое значение
Дисконт	γ	0.95
GAE-параметр	λ_{GAE}	0.95
Размер мини-батча	—	2048 переходов
Эпох на rollout	E	10–32
Клиппинг PPO	ε	0.2
Шаг обучения политики	η_θ	3×10^{-4}
Шаг обучения критика	η_ϕ	3×10^{-4}
Коэффициент value-loss	c_1	0.5
Коэффициент энтропии	c_2	10^{-3}–10^{-2}
Длина rollout	T	2048 шагов

ТАБЛ. 1. Гиперпараметры PPO для теоретической постановки разд. VIII; конкретные значения подлежат уточнению на этапе экспериментальной проверки.

Функция вознаграждения. В соответствии с уравн. (31), общая структура награды:

$$r_t = -|t_t^{\mathrm{render}} - t_t^{\mathrm{perf}}| - \lambda\, \mathscr{L}_{\mathrm{align}}(t) - \mu\, (a_t - a_{t-1})^2.$$

Гиперпараметры $\lambda \in [0.1, 1.0]$ и $\mu \in [0.05, 0.5]$ подбираются на валидации; стандартный приём — начать с малых μ и постепенно увеличивать его в течение обучения, обеспечивая «smooth ramp» от агрессивных тренировок без штрафа гладкости к финальному режиму с полным штрафом.

Связь с двухстадийной схемой ReaLchords. Схема ReaLchords [11] использует офлайнового учителя, видящего всю мелодию целиком, и KL-контроль к нему по уравнению (29). По аналогии в нашем контексте можно представить себе *офлайнового темпо-предсказателя*, имеющего доступ ко всему фрагменту исполнения целиком и оптимально подбирающего темповую траекторию. Тогда онлайновый агент дообучается с дополнительной KL-регуляризацией к этому учителю; такое расширение является потенциально плодотворным методологическим заимствованием и обозначено как направление продолжения работы в разд. IX.