ТЕОРЕТИЧЕСКИЕ ОСНОВЫ ОТСЛЕЖИВАНИЯ ПАРТИТУРЫ В РЕАЛЬНОМ ВРЕМЕНИ: ОТ СКРЫТЫХ МАРКОВСКИХ МОДЕЛЕЙ К ОБУЧЕНИЮ С ПОДКРЕПЛЕНИЕМ

Н. А. Новицкий[1,*] , Н. С. Борисов[2,†]

[1] *АНО Центральный Университет, бывш. НИУ ВШЭ*
[2] *АНО Центральный Университет*

Аннотация. Системы отслеживания партитуры в реальном времени синхронизируют живое исполнение с его нотным текстом и лежат в основе автоматического аккомпанемента, переворота страниц и педагогических обучающих систем. Классические решения — Dynamic Time Warping и скрытые марковские модели — реагируют только на уже случившееся: когда рендерер успевает синтезировать и воспроизвести оркестровый блок, проходит 20–50 мс, что уже на пороге восприятия рассинхронизации. Современные подходы на основе обучения с подкреплением — начиная с работы Дорфера и коллег (2018) и до недавних ReaLchords — полностью заменяют классический трекер нейронным агентом. В настоящей работе предлагается иное: сохранить надёжный вероятностный трекер в качестве ядра системы и добавить к нему лёгкий RL-агент, решающий единственную узкую задачу — предсказать темп исполнителя на горизонте 200–500 мс вперёд. Рендерер использует это предсказание, чтобы стартовать синтез раньше, чем исполнитель доберётся до следующего фрагмента, и тем самым компенсирует системную задержку. Такая постановка — тонкий слой предсказания темпа поверх сохраняемого классического трекера — не совпадает ни с одной из известных авторам групп RL-применений к музыкальному аккомпанементу.

Ключевые слова: отслеживание партитуры, скрытые марковские модели, on-line time warping, обучение с подкреплением, опережающее предсказание темпа, виртуальный оркестр

АКТУАЛЬНОСТЬ И ЦЕЛЬ

Системы автоматического аккомпанемента нужны учащимся консерваторий и концертирующим солистам как замена живого оркестра при подготовке концертных произведений. Технически задача сводится к отслеживанию партитуры в реальном времени (*score following*) [1]: по поступающему каузально потоку наблюдений и заранее известной партитуре требуется оценивать текущую позицию исполнителя с задержкой не более 20 мс — порога восприятия рассинхронизации в музыкальном ансамбле [5]. За четыре десятилетия в области сменилось несколько парадигм: классическое динамическое программирование [2, 3], скрытые марковские модели и их полу-марковские расширения [4–6], современные нейросетевые подходы [7] и относительно новое направление, формализующее задачу как обучение с подкреплением [8, 9, 11]. Появление работ [8, 9, 11] делает актуальным систематический теоретический разбор всего семейства методов. Цель работы — дать математически выверенный, прослеживаемый по литературе фундамент и явно сформулировать, чего в существующих RL-подходах не сделано.

ОСНОВНАЯ ИДЕЯ

Предлагается *гибридная* архитектура (РИС. 1): классический HMM-трекер работает как обычно и на каждом тике (каждые 10 мс) выдаёт своё апостериорное распределение по позициям партитуры $\tilde{\alpha}_t \in \mathbb{R}^N$. Параллельно с ним работает лёгкий RL-агент, который смотрит на текущее состояние трекера и историю темпа за последние 200 мс и предсказывает, с каким темповым коэффициентом a_t нужно играть оркестр в ближайшие 200–500 мс. Рендерер не ждёт — он сразу применяет это предсказание к time-stretching'у оркестрового трека.

Состояние агента s_t включает четыре компонента: $\hat{\alpha}_t$ — сжатое представление апостериорного распределения трекера (насколько уверена модель в текущей позиции исполнителя); $\tau_{t-K:t}$ — последние K оценок темпа (темп за прошлые 200 мс); $e_{t-K:t}$ — последние K значений эмиссионной ошибки (насколько звук отличается от ожидаемого — косвенный признак «нервозности» исполнителя); и $\hat{\varphi}(t)/N$ — текущее положение в партитуре в относительных единицах. Действие $a_t \in [0{,}5; 2{,}0]$ — мультипликативный темповый коэффициент: $a_t = 1{,}0$ означает «играть в номинальном темпе», $a_t = 1{,}2$ — на 20% быстрее, $a_t = 0{,}8$ — на 20% медленнее.

Агент обучается максимизировать суммарное вознаграждение:

$$r_t = -\underbrace{|t_t^{\text{render}} - t_t^{\text{perf}}|}_{\text{рассинхр.}} - \lambda \underbrace{\mathscr{L}_{\text{align}}(t)}_{\text{ошибка трекера}} - \mu \underbrace{(a_t - a_{t-1})^2}_{\text{резкий перепад}} \tag{1}$$

* n.novitskiy@edu.centraluniversity.ru
† n.borisov@edu.centraluniversity.ru

Первое слагаемое — разница между моментом, когда рендерер *реально* выпустил оркестровый звук (t_t^{render}), и моментом, когда солист *фактически* сыграл соответствующую ноту (t_t^{perf}): чем меньше это рассогласование, тем синхроннее ансамбль. Второе — $\mathscr{L}_{\text{align}}$: потеря выравнивания HMM-трекера, гарантирующая, что предсказание темпа не противоречит текущей оценке позиции солиста. Третье — $(a_t - a_{t-1})^2$: штраф за резкие скачки темпа, обеспечивающий гладкость управления. Обучение двустадийное: сначала *behavioural cloning* на реальных записях, затем PPO-дообучение [12] в симуляторе солиста.

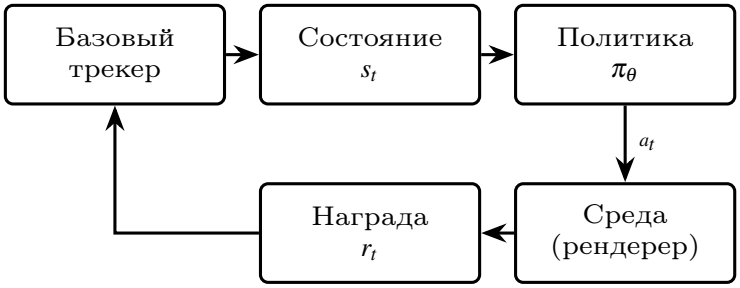

РИС. 1. Схема предлагаемой гибридной архитектуры: базовый вероятностный трекер выдаёт состояние s_t, RL-агент — темповый коэффициент a_t на горизонте 200–500 мс, рендерер и симулятор солиста замыкают обратную связь через вознаграждение r_t.

ПОЛОЖЕНИЕ И ЦЕННОСТЬ

В рамках известных авторам работ предлагаемая схема не попадает ни в одну из четырёх групп: (i) RL-агент *заменяет* трекер целиком [8]; (ii) RL-агент в myopic-режиме решает задачу онлайн-выравнивания символьного входа [9]; (iii) RL применяется к *генерации* нового музыкального материала [10, 11]; (iv) RL применяется к общему KL-контролю предобученной последовательностной модели [13]. Ни одна из перечисленных работ не рассматривает RL-агента как отдельный тонкий слой опережающего предсказания темпа поверх сохраняемого классического трекера. Ожидаемые свойства предложенной рамки: вероятностная интерпретируемость — через forward-распределение HMM всегда понятно, насколько трекер уверен в текущей позиции; возможность адаптации — RL-политику можно дообучить под конкретного солиста на его же записях, не трогая трекер; разделение задач — если трекер теряет позицию, это диагностируется независимо от RL-слоя.

[1] *Dannenberg R. B.* An On-Line Algorithm for Real-Time Accompaniment // Proc. of the International Computer Music Conference (ICMC). — 1984. — P. 193–198.

[2] *Sakoe H., Chiba S.* Dynamic Programming Algorithm Optimization for Spoken Word Recognition // IEEE Trans. on Acoustics, Speech, and Signal Processing. — 1978. — Vol. ASSP-26, No. 1. — P. 43–49.

[3] *Dixon S.* Live Tracking of Musical Performances Using On-Line Time Warping // Proc. of the 8th Int. Conf. on Digital Audio Effects (DAFx). — 2005. — P. 92–97.

[4] *Rabiner L. R.* A Tutorial on Hidden Markov Models and Selected Applications in Speech Recognition // Proc. of the IEEE. — 1989. — Vol. 77, No. 2. — P. 257–286.

[5] *Cont A.* A Coupled Duration-Focused Architecture for Real-Time Music-to-Score Alignment // IEEE Trans. on Pattern Analysis and Machine Intelligence. — 2010. — Vol. 32, No. 6. — P. 974–987.

[6] *Nakamura T., Nakamura E., Sagayama S.* Real-Time Audio-to-Score Alignment of Music Performances Containing Errors and Arbitrary Repeats and Skips // IEEE/ACM TASLP. — 2015. — Vol. 23, No. 11. — P. 1911–1925.

[7] *Henkel F., Widmer G.* Real-Time Music Following in Score Sheet Images via Multi-Resolution Prediction // Frontiers in Computer Science. — 2021. — Vol. 3. — Article 718340.

[8] *Dorfer M., Henkel F., Widmer G.* Learning to Listen, Read, and Follow: Score Following as a Reinforcement Learning Game // Proc. of ISMIR 2018. — P. 784–791.

[9] *Peter S. D.* Online Symbolic Music Alignment with Offline Reinforcement Learning // Proc. of ISMIR 2023. — arXiv:2401.00466.

[10] *Jiang N., Jin S., Duan Z., Zhang C.* RL-Duet: Online Music Accompaniment Generation Using Deep Reinforcement Learning // Proc. of AAAI. — 2020. — Vol. 34. — P. 710–718.

[11] *Wu Y. et al.* Adaptive Accompaniment with ReaLchords // Proc. of the 41st International Conference on Machine Learning (ICML). — 2024. — PMLR 235.

[12] *Schulman J., Wolski F., Dhariwal P., Radford A., Klimov O.* Proximal Policy Optimization Algorithms // arXiv preprint arXiv:1707.06347. — 2017.

[13] *Jaques N. et al.* Sequence Tutor: Conservative Fine-Tuning of Sequence Generation Models with KL-control // Proc. of ICML 2017. — PMLR 70. — P. 1645–1654.